

CPAM-P2-YOLOv8: 基于YOLOv8改进的用于安全帽检测的算法

徐洪帆

青岛大学数学与统计学院, 山东 青岛

收稿日期: 2024年8月29日; 录用日期: 2024年9月23日; 发布日期: 2024年10月10日

摘要

安全帽在保护施工人员免受事故伤害方面发挥着至关重要的作用。然而, 由于种种原因, 工人们并没有严格执行戴安全帽的规定。为了检测工人是否佩戴安全帽, 本文提出了基于YOLOv8改进的目标检测算法(CPAM-P2-YOLOv8)。在YOLOv8的颈部添加CPAM结构, 增强网络对图片的特征提取, 在YOLOv8的头部引入处理后的小目标检测层P2。CPAM-P2-YOLOv8提高了目标检测的精确度, 实验结果表明, 改进模型的精确度达到了91%。与YOLOv8对比, CPAM-P2-YOLOv8的mAP50提高了1.0%, 参数量减少了17%, 同时通过对比发现, CPAM-P2-YOLOv8比YOLOv8在检测小目标方面更有优势。与YOLOv10对比, CPAM-P2-YOLOv8的mAP50提高1.9%。使用知识蒸馏方法, 使CPAM-P2-YOLOv8的精确度进一步提升, 达到91.4%。

关键词

目标检测, YOLOv8, CPAM, 小目标检测, 知识蒸馏

CPAM-P2-YOLOv8: Safety Helmet Detection Algorithm Based on the Improved YOLOv8

Hongfan Xu

School of Mathematics and Statistics, Qingdao University, Qingdao Shandong

Received: Aug. 29th, 2024; accepted: Sep. 23rd, 2024; published: Oct. 10th, 2024

Abstract

Safety helmets play a crucial role in protecting construction workers from accidents and injuries.

文章引用: 徐洪帆. CPAM-P2-YOLOv8: 基于 YOLOv8 改进的用于安全帽检测的算法[J]. 应用数学进展, 2024, 13(10): 4449-4458. DOI: 10.12677/aam.2024.1310424

However, due to various reasons, workers did not strictly adhere to the rule of wearing safety helmets. To detect whether workers are wearing helmets, this article proposes an improved object detection algorithm based on YOLOv8 (CPAM-P2-YOLOv8). Add CPAM structure to the neck network of YOLOv8 to enhance the feature extraction of safety helmets, and introduce a processed small object detection layer P2 at the head of YOLOv8. CPAM-P2-YOLOv8 improved the accuracy of object detection, and experimental results showed that the improved model achieved an accuracy of 91%. Compared with the YOLOv8 model, CPAM-P2-YOLOv8 improved mAP50 by 1.0% and reduced parameter count by 17%. Through comparison, it was found that CPAM-P2-YOLOv8 has more advantages in detecting small targets than YOLOv8. Compared with YOLOv10, the mAP50 of CPAM-P2-YOLOv8 increased by 1.9%. By using the knowledge distillation, the precision of CPAM-P2-YOLOv8 was further improved to 91.4%.

Keywords

Object Detection, YOLOv8, CPAM, Small Object Detection, Knowledge Distillation

Copyright © 2024 by author(s) and Hans Publishers Inc.

This work is licensed under the Creative Commons Attribution International License (CC BY 4.0).

<http://creativecommons.org/licenses/by/4.0/>



Open Access

1. 引言

在当前社会背景下, 安全生产是各行各业高度重视的问题之一, 尤其在建筑工地、矿井等高风险作业环境中, 确保工人的人身安全尤为重要。安全头盔作为最基本的个人防护装备之一, 在保护工人生命安全方面扮演着至关重要的角色。然而, 由于一些工人缺乏足够的安全意识, 不按规定佩戴头盔的情况时有发生, 这给生产安全带来了潜在的风险。

计算机视觉和人工智能技术的迅速发展, 为安全帽检测和管理提供了新的可能性。在这一背景下, 安全帽目标检测成为一个备受关注的研究领域, 其目标是自动地识别工作人员是否佩戴安全帽。已有的一些算法可以识别图像中的多个物体, 并判断出它们的类别和位置, 因此在产品安全领域中引起了研究人员的高度关注。

传统的物体检测方法通常采用基于滑动窗口的区域选择策略[1], 这种方法不仅针对性不强, 而且计算复杂度较高。此外, 依赖于手工设计的特征提取器对于目标多样性处理的能力有限。近年来, 得益于 GPU 性能的提升以及深度学习方法的发展, 卷积神经网络(CNN)因其无须手动设计特征提取过程的优势, 在目标检测任务中得到了广泛应用。根据是否有候选框, 算法分为两阶段目标检测算法和一阶段目标检测算法。两阶段算法, 如 R-CNN [2]、Faster R-CNN [3], 根据检测算法提前生成候选区, 然后再对候选区进行分析。一阶段算法, 如 SSD [4]、YOLO 系列[5], 可以实现端到端的检测, 能够在一次前向传播中同时完成目标检测和定位, 具有高效性和准确性的优势。然而, 传统 YOLO 模型在头盔目标检测中仍然面临一些挑战, 例如 YOLOv8n 网络参数多、不同尺度目标的检测问题等。因此, 改进和优化 YOLO 模型以适应安全帽目标检测的需求成为国内外学者的研究目标[6] [7]。

为了提高 YOLOv8 在目标检测的性能, 引入了通道和位置注意力机制(Channel and Position Attention Mechanism, CPAM), 使 YOLOv8 模型更加关注具有丰富信息的目标特征。

为了适应真实的安全帽应用场景存在小目标[8]的情况, 在 YOLOv8 的基础上, 新增小目标检测层 P2, 增加小目标特征信息量。

2. 模型原理

2.1. CPAM

CPAM 是 ASF-YOLO [9] 中的一个注意力机制。ASF-YOLO 是一种基于 YOLO 框架创新的目标检测模型，专为细胞实例分割设计，它结合了空间和尺度特征，旨在实现快速而精准的细胞识别与分割。在 YOLO 分割框架的基础上，ASF-YOLO 引入了尺度序列特征融合(Scale Sequence Feature Fusion, SSFF)模块来增强网络的多尺度信息提取能力，并采用了三重特征编码器(Triple Feature Encoder, TFE)来融合不同尺度的特征图以增加细节信息。SSFF 模块对输入的特征图进行卷积、差值(Interpolation)、维度扩展(Unsqueeze)，最后，使用卷积、批处理归一化和 LeakyReLU 激活函数完成尺度序列特征提取。

在 ASF-YOLO 中，CPAM 用以整合 SSFF 和 TFE 模块，重点关注信息通道和空间位置相关的小对象，以提高检测和分割性能。为了提高 YOLOv8 在目标检测的性能，使其更加关注具有丰富信息的目标特征，引入了 CPAM 和 SSFF。

CPAM 的结构如图 1 所示，它包括通道注意网络(Channel attention network)和位置注意网络(Position attention network)。在本文改进的 YOLOv8 中，通道注意网络的输入是处理后的 P3 特征图(输入 1)，位置注意网络的输入是输出 1 和 SSFF 输出(输入 2)的叠加。




Figure 1. The structure of CPAM module

图 1. CPAM 的结构图

通道注意力机制的结构见图 1 的左侧虚线框内。通道注意力机制通过关注重要的特征通道来提升模型的表现，其首先对输入特征图 F 进行全局平均池化，数据重塑，应用一维卷积层和 Sigmoid 函数，生成每个通道的权重。为了捕获跨通道的相互作用，考虑每个通道及其 k 个最近邻通道，使用核为 k 的 1 维卷积实现，即核大小 k 表示局部跨通道相互作用的覆盖范围。由于卷积核大小 k 与通道维数 C 成正比，通道维数一般为 2 的指数，可以将 k 定义为

$$k = \psi(C) = \left\lceil \frac{\log_2(C) + b}{\gamma} \right\rceil_{\text{odd}} \quad (1)$$

其中 γ 和 b 是控制卷积核大小 k 与通道维度 C 之比的缩放参数。式中 $\lceil \cdot \rceil_{\text{odd}}$ 代表对向上取奇数。实验中，将 γ 的值设为 2， b 设为 1。

位置注意力机制的结构见图 1 的右侧虚线框内。位置注意力机制通过关注重要的空间位置来提升模型的表现。将输出 1 与来自 SSFF 的特征(输入 2)相结合作为位置注意网络的输入，可以提供互补信息，从特征中提取关键的位置信息。

与通道注意机制相比，位置注意机制首先根据输入特征图 x 的宽度 w 和高度 h 将其分成两部分，分别在高度方向和宽度方向进行空间平均池化，得到 x_h, x_w 。将拼接后的 x_h, x_w 通过卷积层和激活函数，见公式(2)，(3)。

$$\text{Concat}(x_h, x_w) = \begin{bmatrix} x_h \\ x_w \end{bmatrix} \quad (2)$$

$$\text{ReLU}\left(\text{BN}\left(\text{Conv} \times \left(\text{Concat}(x_h, x_w)\right)\right)\right) = \text{ReLU}\left(\text{BN}\left(\text{Conv} \times \begin{bmatrix} x_h \\ x_w \end{bmatrix}\right)\right) \quad (3)$$

其中 Concat 是拼接操作，Conv 是一个卷积层，BN 表示批量归一化，ReLU 是激活函数。

然后分离高度和宽度的特征图，并应用卷积层来生成权重。

$$s_h = \sigma\left(\text{Conv} \times \left(\text{ReLU}\left(\text{BN}\left(\text{Conv} \times (x_h)\right)\right)\right)\right) \quad (4)$$

$$s_w = \sigma\left(\text{Conv} \times \left(\text{ReLU}\left(\text{BN}\left(\text{Conv} \times 1(x_w)\right)\right)\right)\right) \quad (5)$$

σ 表示 Sigmoid 函数。

最后，使用生成的高度和宽度方向的权重对原始特征图进行加权，得到输出 out：

$$\text{out} = x \cdot s_h \cdot s_w \quad (6)$$

2.2. YOLOv8

YOLOv8 是 Ultralytics 公司推出的基于目标检测模型的 YOLO 系列之一。YOLOv8 共有 YOLOv8n、YOLOv8s1、YOLOv8m、YOLOv8l 和 YOLOv8x 五个版本，检测精度和模型大小依次增加。考虑到精度、模型大小和检测速度，本文选择以 YOLOv8n 作为基准算法，在此基础上进行改进和创新。

YOLOv8 算法模型结构主要由输入端(Input)、主干网络(Backbone)和头部(Head)组成，其中头部包括了颈部网络(Neck)和检测头(Detect)。在输入端部分，功能包括了马赛克(Mosaic)数据增强、自适应锚框(Anchor)计算和其他数据增强技术。实验设置 YOLOv8 输入的是一张三维尺寸为 640 * 640 的图像，然后利用卷积神经网络将输入图像转换成特征图。网络会预测边界框的位置、大小和相关物体的概率，并根据预测结果生成目标检测结果。

相比较传统的目标检测算法，该算法模型在不损失检测精度的前提下具有更快的检测速度、更轻量的算法模型等优点。YOLOv8 在 YOLOv5 的基础上进行了优化，用 C2f(包括两个卷积层的 CSP bottleneck)模块替换了 YOLOv5 中的 C3(包含三个卷积层的 CSP bottleneck)模块，C2f 模块包含更多的跳跃连接和 split 操作，减少了计算量并增强了特征信息的传递。YOLOv8 不仅限于目标检测，还支持实例分割和关键点检测，这使得它成为一个多用途的计算机视觉工具。YOLOv8 采用了无锚点的检测方法，简化了框的预测过程，提高了检测效率。

2.3. 小目标检测头

YOLOv8 主干中的 1~5 级特征提取分支 P1、P2、P3、P4、P5，对应与这些特征映射相关联的 YOLO

网络输出。在 YOLOv8 的特征提取阶段，使用多个 C2f 模块堆叠为主干，然后将主干的三个有效特征分支 P3、P4、P5 作为特征金字塔网络[10]结构的输入，在颈部构建特征融合结构，如图 2 的黑色箭头。




Figure 2. An abridged general view of the framework of YOLOv8 and addition of P2 layer

图 2. YOLOv8 的框架及 P2 层的加入

真实的安全帽应用场景中，建筑工地施工现场获得的图片由于相机距离目标较远、颜色亮度不匹配、拍摄角度不合适、恶劣天气等情况下存在小目标情况。在改进的方法中，在特征金字塔中加入专门针对小目标的 P2 层，如图 2 的蓝色箭头。P2 层的加入，可以改善目标检测系统中小目标可能被忽视或定位不准确的问题。

2.4. 算法改进说明

1) 在 YOLOv8 的颈部引入 CPAM 架构，搭配 SSFF，其作用是提取不同通道中包含的代表性特征信息。

2) 在 YOLOv8 的头部引入小目标检测层 P2，作为更浅的特征层，其可以改善下采样带来的小目标信息丢失导致模型在较深的特征图中很难精准定位和识别小目标这一问题。

改进后的网络(下文称 CPAM-P2-YOLOv8)结构如图 3，在网络第 25 层加入了 CPAM。处理后的 P2 特征图对应于网络的第 30 层，最终的检测头接收 P2、P3、P4 和 P5 特征图作为输入，进行最终的目标检测。

3. 实验的结果与分析

3.1. 实验平台及参数设置

在本文实验使用 Colab 平台，深度学习的框架为 torch-2.3.1+cu121，语言版本为 Python3.10.12，GPU

为 NVIDIA Tesla T4, 15102MiB, CPU 为 Intel(R) Xeon(R) CPU @ 2.20GHz, Cuda 版本为 12.2。实验环境的配置参数如表 1 所示。

主要训练参数配置如表 2 所示。




Figure 3. Diagram of the CPAM-P2-YOLOv8n model architecture
图 3. CPAM-P2-YOLOv8n 的结构

Table 1. Configuration parameters of the test environment
表 1. 测试环境的配置参数

参数	版本或数值
操作平台	Colab
CPU	Intel(R) Xeon(R) CPU @ 2.20GHz
GPU	NVIDIA Tesla T4, 15102MiB
CUDA	12.2
Pytorch	torch-2.3.1+cu121
Python	3.10.12

Table 2. Training parameters
表 2. 训练参数配置

参数名称	配置
Epochs	100
Batchsize	8

续表

workers	8
Optimizer	SGD
close_mosaic	10
imgsz	640

3.2. 数据集介绍

本次实验采用 GDUT-HWD 安全帽数据集[6]。GDUT-HWD 数据集是一个专门为检测建筑工地上工人是否佩戴安全帽以及识别安全帽颜色而创建的基准数据集。总共包含 3174 张图像。本文按照 7:1:2 划分训练集、验证集与测试集，2221 张用于训练集，318 张用于验证集，另外 635 张用于测试集。数据集中共有 18,893 个实例，被分为 5 个类别：蓝色、黄色、白色、红色、未佩戴安全帽。每个实例都带有类别标签和边界框标注。特别的是，数据集集中的小规模实例(面积 $\leq 32^2$ 像素)数量最多，这为安全帽检测带来了挑战。

相比于其他研究使用的安全帽数据集[11]，GDUT-HWD 要求检测所有佩戴和未佩戴安全帽的工人，并识别安全帽的颜色。颜色识别有助于区分工地上的不同角色，从而增强安全管理。数据集注重头区域的边界框标注，而非整个工人身体，这减少了背景像素对检测的影响，提高了检测的鲁棒性。

3.3. 实验结果

实验采用精度(Precision, P)、召回率(Recall, R)、所有类别平均精度值(Mean Average Precision, mAP, 参数量(Parameters)、运算量(GFLOPs)、模型体积评估本文所提算法的性能，其中精度，召回率，mAP 的公式分别是：

$$\text{Precision} = \frac{TP}{TP + FP} \quad (7)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (8)$$

$$\text{mAP} = \frac{\sum_{i=1}^N AP_i}{N} = \int_0^1 P(R) dR \quad (9)$$

TP (True Positives): 实际正类预测为正类的数量。

TN (True Negative): 实际负类预测为负类的数量。

FP (False Positives): 实际负类预测为正类的数量。

FN (False Negative): 实际正类预测为负类的数量。

N 为类别数量。

各类的平均精度(Average Precision, AP)可以被视为精确率与召回率曲线(PR 曲线)下的面积，mAP 则是衡量所有类别的平均均度。mAP50 是在 IOU (交并比)为 0.5 时的 mAP。

YOLOv10 [12]是 2024 年 5 月 25 日由清华多媒体智能组发布的用于实时端到端对象检测的新一代 YOLO 系列。SSD-RPA512 是由数据集 GDUT-HWD 的创建者发布的 SOTA 模型。本次实验将 YOLOv8n、YOLOv10、SSD-RPA512 与 CPAM-P2-YOLOv8n 作对比，得出 CPAM-P2-YOLOv8n 模型相比于 YOLOv8n 模型 mAP 值提高了 1.1%，参数量减少了 17%。具体结果如表 3 所示。由此可见，CPAM-P2-YOLOv8n 模型在安全帽检测方面性能更佳。

Table 3. System resulting data of standard experiment
表 3. 对比试验结果

模型	<i>P</i>	<i>R</i>	mAP50%	参数量	GFLOPs	模型体积(MB)
YOLOv8n	0.907	0.837	90.5	3,006,623	8.1	6.3
YOLOv10n	0.899	0.807	89.6	2,266,143	6.5	5.8
SSD-RPA512	---	---	83.9	---	---	---
CPAM-P2-YOLOv8n	0.910	0.845	91.5	2,490,607	12.0	5.4
CPAM-P2-YOLOv8m	0.918	0.858	93.0	22,610,721	94.8	45.7
CPAM-P2-YOLOv8n (学生模型)	0.914	0.838	91.6	2,490,607	12.0	5.4


与 YOLOv8n 相比,CPAM-P2-YOLOv8n 的精度、召回率和 mAP50(下文称三项指标)分别高了 0.3%、0.8%和 1.0%。同时 CPAM-P2-YOLOv8n 的参数量和模型体积显著低于 YOLOv8n, 更适合部署在资源受限的设备上。由于 CPAM 和 P2 引入, GFLOPs 在可接受范围内有所提高。

与 YOLOv10n 相比, CPAM-P2-YOLOv8n 的三项指标分别高了 1.1%、3.8%和 1.9%。同时在参数量和模型体积方面, 两者差别不大且均优于 YOLOv8n。

与之前的研究中 SSD-RPA512 相比, CPAM-P2-YOLOv8n 的 mAP50 高了 7.6%, 精度显著提高。

由于 CPAM-P2-YOLOv8m 的参数和模型体积大幅增加, 其精度明显高于其他模型。与 CPAM-P2-YOLOv8n 相比, 其三项指标分别高 0.8%、1.3%、1.5%。大模型的训练往往耗费更多的资源, 其 GFLOPs 高达 94.8。为了提高模型利用率, 以 CPAM-P2-YOLOv8m 作为教师模型, 通过逐层知识蒸馏(Channel-wise Knowledge Distillation) [13]训练 CPAM-P2-YOLOv8n (学生模型)。经过实验发现, 选择网络中的 13, 17, 20, 23, 28 层作为蒸馏层时, 学生模型学习效果最佳。学生模型的精度和 mAP50 分别比采用传统的训练方法时的 CPAM-P2-YOLOv8n 高了 0.4%、0.1%。

根据应用场景的不同, 可以选择适合的模型。如果追求更高的性能并且资源充足, CPAM-P2-YOLOv8m 可能是更好的选择。如果需要平衡性能和资源使用, 则 CPAM-P2-YOLOv8 更为合适。具体实验结果如图 4 所示。






Figure 4. Comparison diagram of experiments with different models

图 4. 不同模型的实验对比图

安全帽检测结果如图 5 所示,第一行图片为标签,第二行为 CPAM-P2-YOLOv8n 模型所检测的结果,第三行为 YOLOv8n 模型所检测的结果。左侧图片中 YOLOv8n 出现了预测错误;右侧图片出现小目标遮挡的情况,经过对比可以得出 CPAM-P2-YOLOv8n 模型对安全帽的小目标检测比 YOLOv8 更加好。



Figure 5. Comparison diagram of CPAM-P2-YOLOv8n VS YOLOv8n

图 5. CPAM-P2-YOLOv8n 与 YOLOv8n 预测对比图

4. 结论

安全帽目标检测有很大的研究价值,保护工作人员生命安全应放在生产工作的第一位。做好安全帽检测工作可以防患于未然,对于个人和社会都有重要意义。本文应用 GDUT-HWD 数据集,在 YOLOv8

的基础上引入 CPAM 架构和 P2 检测层, CPAM-P2-YOLOv8n 模型比 YOLOv8 模型在精度和 mAP50 上都有提升。除此之外,与其他模型比较,CPAM-P2-YOLOv8n 在检测安全帽方面有明显优势。P2 检测层的引入使其在小目标检测上更加精准。未来可以通过剪枝、进一步的蒸馏和模型轻量化等手段来减少模型参数,降低计算量提升检测速度。

参考文献

- [1] Xu, Y., Yu, G., Wang, Y., Wu, X. and Ma, Y. (2016) A Hybrid Vehicle Detection Method Based on Viola-Jones and HOG + SVM from UAV Images. *Sensors*, **16**, Article No. 1325. <https://doi.org/10.3390/s16081325>
- [2] Girshick, R., Donahue, J., Darrell, T. and Malik, J. (2014) Rich Feature Hierarchies for Accurate Object Detection and Semantic Segmentation. 2014 *IEEE Conference on Computer Vision and Pattern Recognition*, Columbus, 23-28 June 2014, 580-587. <https://doi.org/10.1109/cvpr.2014.81>
- [3] Girshick, R. (2015) Fast R-CNN. 2015 *IEEE International Conference on Computer Vision (ICCV)*, Santiago, 7-13 December 2015, 1440-1448. <https://doi.org/10.1109/iccv.2015.169>
- [4] Liu, W., Anguelov, D., Erhan, D., Szegedy, C., Reed, S., Fu, C., et al. (2016) SSD: Single Shot MultiBox Detector. *Computer Vision—ECCV 2016*, Amsterdam, 11-14 October 2016, 21-37. https://doi.org/10.1007/978-3-319-46448-0_2
- [5] Redmon, J., Divvala, S., Girshick, R. and Farhadi, A. (2016) You Only Look Once: Unified, Real-Time Object Detection. 2016 *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Las Vegas, 27-30 June 2016, 779-788. <https://doi.org/10.1109/cvpr.2016.91>
- [6] Wu, J., Cai, N., Chen, W., Wang, H. and Wang, G. (2019) Automatic Detection of Hardhats Worn by Construction Personnel: A Deep Learning Approach and Benchmark Dataset. *Automation in Construction*, **106**, Article 102894. <https://doi.org/10.1016/j.autcon.2019.102894>
- [7] Shrestha, K., Shrestha, P.P., Bajracharya, D. and Yfantis, E.A. (2015) Hard-Hat Detection for Construction Safety Visualization. *Journal of Construction Engineering*, **2015**, Article 721380. <https://doi.org/10.1155/2015/721380>
- [8] Liu, Y., Sun, P., Wergeles, N. and Shang, Y. (2021) A Survey and Performance Evaluation of Deep Learning Methods for Small Object Detection. *Expert Systems with Applications*, **172**, Article 114602. <https://doi.org/10.1016/j.eswa.2021.114602>
- [9] Kang, M., Ting, C., Ting, F.F. and Phan, R.C.-W. (2024) ASF-YOLO: A Novel YOLO Model with Attentional Scale Sequence Fusion for Cell Instance Segmentation. *Image and Vision Computing*, **147**, Article 105057. <https://doi.org/10.1016/j.imavis.2024.105057>
- [10] Lin, T., Dollar, P., Girshick, R., He, K., Hariharan, B. and Belongie, S. (2017) Feature Pyramid Networks for Object Detection. 2017 *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Honolulu, 21-26 July 2017, 936-944. <https://doi.org/10.1109/cvpr.2017.106>
- [11] Zhou, F., Zhao, H. and Nie, Z. (2021) Safety Helmet Detection Based on YOLOv5. 2021 *IEEE International Conference on Power Electronics, Computer Applications (ICPECA)*, Shenyang, 22-24 January 2021, 6-11. <https://doi.org/10.1109/icpeca51329.2021.9362711>
- [12] Wang, A., Chen, H., Liu, L., Chen, K., Lin, Z., Han, J. and Ding, G. (2024) YOLOv10: Real-Time End-to-End Object Detection. arXiv: 2405.14458. <https://doi.org/10.48550/arXiv.2405.14458>
- [13] Shu, C., Liu, Y., Gao, J., Yan, Z. and Shen, C. (2021) Channel-Wise Knowledge Distillation for Dense Prediction. 2021 *IEEE/CVF International Conference on Computer Vision (ICCV)*, Montreal, 10-17 October 2021, 5291-5300. <https://doi.org/10.1109/iccv48922.2021.00526>