



设计（论文）题目

基于深度学习的交通零部件缺陷检测系统设计与实现

设计（论文）英文题目

Design and Implementation of a Traffic Component Defect
Detection System Based on Deep Learning

学 院：_____软件学院_____

专 业：_____软件工程_____

学生姓名：_____梁曦霖_____

学 号：_____22301094_____

指导教师：_____吴睿智_____

北京交通大学

2026 年 6 月

工作日志列表

1. 北京交通大学毕业设计（论文）任务书
2. 北京交通大学毕业设计（论文）开题报告
3. 北京交通大学毕业设计（论文）指导手册
4. 北京交通大学毕业设计（论文）外文原文与译文

题 目： 基于深度学习的交通零部件缺陷检测系统设计与实现

学院： 软件学院 专业： 软件工程 学生姓名： 梁曦霖 学号： 22301094

指导教师（签名）： 吴睿智 提交日期： 2026 年 1 月 19 日

毕业设计（论文）基本内容和要求：

本毕业设计围绕人工智能在交通工程领域中的实际应用，设计并实现一个基于深度学习的交通零部件缺陷检测系统。系统以交通相关金属零部件、结构构件或典型工业构件为研究对象，利用深度学习目标检测算法实现缺陷的自动识别与定位。

论文基本内容包括：

- (1) 分析交通工程领域中零部件缺陷检测的研究背景与工程需求；
- (2) 调研国内外基于计算机视觉与深度学习的缺陷检测研究现状；
- (3) 基于 YOLOv8 目标检测算法构建缺陷识别模型，并完成模型训练与性能评估；
- (4) 设计并实现基于 B/S 架构的缺陷检测系统，实现图像上传、缺陷检测与结果可视化；
- (5) 对系统整体功能与实验结果进行分析与总结。

毕业设计（论文）拟解决的关键问题：

- (1) 如何将深度学习目标检测算法应用于交通零部件缺陷检测场景；
- (2) 如何构建适用于缺陷检测的图像数据集并进行有效标注；
- (3) 如何提升模型在复杂背景下的检测准确率与鲁棒性；
- (4) 如何将检测模型与 Web 系统进行集成，实现算法工程化落地；
- (5) 如何在保证检测效果的前提下降低系统运行复杂度。

毕业设计（论文）应完成的工作：

- (1) 完成交通零部件缺陷检测相关文献调研；
- (2) 掌握深度学习与目标检测基本原理；
- (3) 构建缺陷检测数据集并完成预处理；
- (4) 基于 YOLOv8 模型进行训练与参数调优；
- (5) 设计系统总体架构与功能模块；
- (6) 基于 Flask 实现缺陷检测 Web 系统；
- (7) 完成系统测试与实验结果分析；
- (8) 撰写毕业设计论文并完成答辩准备。

参考资料推荐：

- [1] Saberironaghi A, Ren J, El-Gindy M, et al. Defect detection methods for industrial products using deep learning techniques[J]. Algorithms, 2023, 16(2): 95. doi:10.3390/a16020095.

- [2] Zhang Z, Zhou M, Wan H, et al. IDD-Net: Industrial defect detection method based on deep learning[J]. Engineering Applications of Artificial Intelligence, 2023, 123: 106390. doi:10.1016/j.engappai.2023.106390.

- [3] Xie Y, Hu W, Xie S, et al. Surface defect detection algorithm based on feature-enhanced YOLO[J]. Cognitive Computation, 2023, 15(2): 565 - 579. doi:10.1007/s12559-022-10061-z.

- [4] Hussain M. YOLO-v1 to YOLO-v8: the rise of YOLO and its complementary nature toward digital manufacturing and industrial defect detection[J]. Machines, 2023, 11(7): 677. doi:10.3390/machines11070677.

其他要说明的问题：无

题 目： 基于深度学习的交通零部件缺陷检测系统设计与实现

一、项目背景

随着智能制造与工业自动化水平的不断提升，工业生产过程正朝着数字化、信息化与智能化方向加速发展。在这一背景下，产品质量检测作为保障生产稳定运行与提升产品可靠性的关键环节，其重要性日益凸显。高效、精准的质量检测不仅直接关系到企业的经济效益与品牌信誉，也在一定程度上影响产业链整体的安全性与竞争力。传统的人工目检方式依赖操作人员的经验与主观判断，存在检测效率低、劳动强度大、结果一致性差、易受疲劳与环境因素影响等问题，难以满足现代工业对高精度、高一致性与高实时性的检测需求。

近年来，基于计算机视觉的自动化检测技术迅速发展，逐渐成为工业质量检测领域的重要研究方向。尤其是以深度学习为核心的视觉算法，在特征自动提取、复杂模式建模以及端到端优化方面展现出显著优势。相比传统基于人工设计特征的方法，深度卷积神经网络能够从原始图像中自动学习多层次语义特征，有效提升对复杂缺陷形态的表达能力和对多样化场景的适应能力。在目标检测领域，诸如 YOLO（You Only Look Once）系列算法通过单阶段检测框架实现了速度与精度的良好平衡，在实时工业检测场景中具有较高的应用价值。其后续版本如 YOLOv8 在网络结构设计、损失函数优化以及训练策略改进等方面持续演进，使其在小目标检测与复杂背景建模中具备更强的性能表现。

在众多工业视觉任务中，交通零部件及钢材表面缺陷检测具有较强的代表性与研究价值。例如，在公开数据集中，NEU-DET 所包含的钢材表面缺陷类别多样，包括裂纹、划痕、压痕等不同类型缺陷，这些缺陷在尺度、形态与对比度方面存在显著差异。实际工业场景中，缺陷往往呈现出尺寸变化范围大、边缘模糊、纹理复杂以及与背景相似度高等特征，对检测模型的特征提取能力、尺度适应能力以及泛化能力提出了较高要求。同时，生产环境中光照变化、噪声干扰与拍摄角度差异等因素，也进一步增加了模型部署与实际应用的难度。

尽管深度学习方法在工业缺陷检测中已取得一定进展，但其性能高度依赖于大规模、高质量的标注数据。在真实工业场景中，图像采集相对容易，而精确标注却需要具备专业知识的技术人员逐一标记缺陷位置与类别，时间成本与经济成本较高。部分缺陷样本数量稀缺，类别分布不均衡，也会导致模型在训练过程中出现偏置问题，限制其实际推广应用。因此，在标注数据有限的条件下，如何充分利用现有数据资源，

提高模型性能与训练效率，成为当前亟需解决的重要问题。

为缓解标注数据不足带来的限制，半监督学习逐渐成为研究热点。该方法通过联合使用少量有标签数据与大量无标签数据进行训练，在理论上能够挖掘未标注数据中蕴含的潜在信息，从而提升模型的泛化能力。然而，在目标检测任务中，半监督学习面临更为复杂的挑战。一方面，伪标签生成过程容易引入噪声，当模型预测结果存在偏差时，错误标签可能被反复强化，导致误差累积；另一方面，目标定位与分类任务的耦合特性，使得框位置误差与类别误判相互影响，进一步增加了训练的不稳定性。因此，如何设计合理的伪标签筛选机制、置信度阈值策略以及多阶段训练流程，以抑制噪声传播并稳定模型收敛，是当前研究的关键问题。

基于上述背景，本文拟在标注数据受限的条件下，围绕交通零部件与钢材表面缺陷检测任务，构建基于深度学习的目标检测框架，系统探索半监督学习在工业缺陷检测中的适用性与性能提升机制。通过对模型结构优化、训练策略设计以及伪标签质量控制方法的研究，分析半监督方法在实际工业场景中的有效性与局限性。该研究不仅有助于提升工业缺陷检测系统在低标注资源环境下的实用价值，也为半监督目标检测算法在工程领域的应用提供一定的理论支撑与实践参考。

二、项目内容、项目目标与拟解决的关键问题

（一）研究内容

本课题以 NEU-DET 数据集为研究对象，围绕交通零部件（钢材表面）缺陷检测任务，系统开展模型构建、策略优化与半监督训练机制研究，具体包括以下几个方面：

（1）基于 YOLOv8 算法构建交通零部件缺陷检测的基线模型（Baseline）。在标准训练设置下完成模型训练、验证与测试过程，统计 Precision、Recall、mAP 等指标，分析模型在不同缺陷类别上的检测表现与误检、漏检情况，为后续改进提供对照基础。

（2）在 Baseline 模型基础上，围绕模型训练策略与损失函数参数进行系统性优化。包括对学习率策略、批大小、训练轮次、数据增强方式等超参数进行调节，同时分析分类损失与定位损失权重比例对模型性能的影响，探索在数据充足条件下的最优训练配置，从而获得性能相对稳定、收敛性良好的改进模型。

（3）结合真实工业场景中“标注数据有限”的实际问题，对数据集进行重新划

分，构建少量有标签数据与大量无标签数据并存的训练环境。通过人为控制有标签样本比例（如 10%、20%等），模拟标注资源受限的应用场景，为后续半监督学习实验建立可控变量条件。

（4）构建半监督学习流程。首先利用少量有标签数据训练初始 Seed 模型；随后使用该模型对无标签数据进行推理，生成伪标签（Pseudo-label）；通过设定置信度阈值与筛选策略，构建由真实标注数据与伪标注数据组成的混合训练集，进一步训练目标检测模型，实现知识迁移与数据扩充。

（5）设计并比较不同伪标签策略与训练机制。包括不同置信度阈值设置、是否采用多阶段迭代更新、是否动态更新伪标签、是否进行类别平衡约束等策略，对比其对检测性能与模型稳定性的影响。通过定量实验分析半监督方法在不同数据比例下的效果差异，评估其实际收益与风险。

（6）结合实验结果，对半监督目标检测在工业缺陷检测任务中的适用性进行系统总结。重点分析其在提升小样本类别检测能力、改善泛化性能方面的优势，以及在伪标签噪声放大、误差累积等方面存在的局限性，形成具有工程指导意义的结论。

（7）在获得最终优化模型后，完成缺陷检测系统的前后端搭建。包括模型推理接口封装、图像输入与结果可视化模块设计，以及基本的用户交互界面开发，构建具备实际应用场景演示能力的系统原型，为后续工程部署奠定基础。

（二）研究目标

本课题围绕“数据受限条件下的工业缺陷检测模型优化”这一核心问题，拟实现以下目标：

（1）设计并实现一个结构清晰、性能稳定的交通零部件缺陷检测模型，能够在标准数据条件下达到较为理想的检测精度，并具备一定的泛化能力。

（2）在标注数据有限的条件下，引入半监督学习方法，系统分析其对模型检测性能、收敛速度与稳定性的影响，验证半监督机制在工业缺陷检测场景中的可行性。

（3）通过对比实验与消融实验，深入分析伪标签质量、置信度阈值设置、数据比例变化以及训练策略调整等因素对模型性能的影响，揭示半监督目标检测性能变化

的内在原因。

（4）提出适用于工业缺陷检测场景的数据利用与训练策略方案，为实际生产环境中“标注资源有限但无标签数据充足”的问题提供技术参考与实验依据。

（5）完成一个具有实际应用价值的交通零部件缺陷检测系统原型，实现模型从算法验证到系统实现的完整闭环，为后续工程化部署与功能扩展提供基础框架。

（三）拟解决的关键问题

（1）在标注数据充足条件下，如何确定最优训练策略的问题。包括如何合理设置学习率与损失权重、如何平衡检测精度与推理速度，以及如何提高模型对不同缺陷尺度与类别的适应能力，从而获得性能稳定的基线模型。

（2）在标注数据有限条件下模型性能显著下降的问题。目标检测模型通常依赖大量标注样本进行训练，当样本数量减少时，模型容易出现过拟合或欠拟合现象。本课题需要探索在少量有标签数据条件下，如何通过合理的数据划分与训练流程设计，维持模型的基本检测能力。

（3）伪标签噪声对模型训练带来的负面影响问题。由于伪标签来源于模型预测结果，其准确性无法完全保证，错误标签可能导致模型学习到错误的特征分布，甚至引发误差累积。因此，需要研究有效的伪标签筛选机制与置信度控制策略，以降低噪声对模型收敛过程的干扰。

（4）半监督训练策略的有效性与稳定性问题。不同伪标签生成方式、不同数据混合比例以及不同训练阶段安排，都会对模型性能产生显著影响。本课题需要通过系统实验对比，分析各类策略在工业缺陷检测任务中的适用性与稳定性，明确其优势边界与潜在风险，为实际工程应用提供可靠依据。

三、拟采取的解决方案及可行性分析

（一）解决方案

（1）采用 YOLOv8 作为目标检测的基础框架，构建交通零部件（钢材表面）缺陷检测模型。结合其单阶段检测结构和较优的速度 - 精度平衡特性，完成网络结构配置、损失函数设置及训练流程设计。

（2）基于 NEU-DET 数据集，在全监督条件下完成 Baseline 模型训练，系统记录各项性能指标，并通过调整学习率策略、损失函数权重及数据增强方式，对模型进行适度优化，获得改进后的对照模型，为后续半监督实验提供稳定基准。

（3）对数据集进行重新划分，构建有标签数据（Seed）、无标签数据（Unlabeled）以及独立测试集三部分数据结构。通过控制有标签数据比例，模拟真实工业场景中“标注样本有限但未标注样本充足”的情况，保证实验环境的可控性与对比性。

（4）利用 Seed 数据训练初始模型（Seed Model），在验证其具备基本检测能力后，对无标签数据进行推理，生成伪标签。通过设定合理的置信度阈值与筛选规则，过滤低质量预测结果，提升伪标签整体可靠性。

（5）将真实标注数据与伪标签数据进行整合，构建混合训练集，开展半监督训练。根据实验需求，可采用单阶段或多阶段训练流程，对伪标签进行一次或多次更新，以比较不同训练策略对模型性能与稳定性的影响。

（6）结合多组实验结果，从检测精度、收敛稳定性及泛化能力等方面进行综合评估，选取性能稳定、误检率较低且泛化能力较强的模型用于后续系统实现与演示部署。

（二）可行性分析

（1）理论可行性：YOLO 系列算法在目标检测领域已形成较为成熟的理论体系与工程实践经验，半监督学习方法在图像分类与目标检测领域也已有大量研究成果，为本课题提供了坚实的理论基础与方法参考。

（2）数据可行性：NEU-DET 数据集为公开数据集，数据获取便捷，缺陷类别清晰、规模适中，既能够支撑全监督训练，也适合构建半监督实验环境，满足课题研究需求。

（3）技术可行性：本课题依托 PyTorch 深度学习框架及 Ultralytics 提供的 YOLOv8 实现工具，训练流程成熟、接口完善，实验环境配置清晰，可在现有硬件条件

下稳定运行。相关模型训练、评估与部署技术已具备一定实践基础，技术风险可控。

（4）时间可行性：研究内容聚焦于模型训练策略优化与半监督流程验证，任务边界明确，实验规模可控，既具有一定研究深度，又符合本科毕业设计的工作量要求。在合理安排实验进度与阶段目标的前提下，可在规定时间内完成模型训练、结果分析及系统原型搭建工作。

（三）技术路线图

本课题技术路线分为五个主要阶段：数据准备阶段对 NEU-DET 数据集进行有标签/无标签/测试集划分；基线模型阶段基于 YOLOv8 进行全监督训练与超参数优化，获得 Baseline 模型；半监督学习阶段通过 Seed 模型生成伪标签，经阈值筛选后进行混合训练；对比实验阶段分析不同数据比例、阈值策略和训练方式对性能的影响，筛选最优模型；系统实现阶段完成模型封装与前端界面开发，实现缺陷检测演示功能。




图 1 技术路线图

（四）系统架构图文字说明

系统采用三层架构：用户层负责图像上传与检测结果展示；应用层提供推理接口、图像预处理和结果可视化服务；模型与数据层包含 YOLOv8 检测模型、NEU-DET 数据集和离线训练模块。数据流向为：用户上传图像→应用层预处理→模型推理→结果可视化→前端展示，形成完整的检测闭环。




图 2 系统架构图

主要参考文献:

[1] MAITY A, GHOSH T. Comparative Analysis of Object Detection Algorithms for Surface Defect Detection[J].

[2] ALOMAR K, AYSEL H I, CAI X. Data Augmentation in Classification and Segmentation: A Survey and New Strategies[J/OL]. Journal of Imaging, 2023,

9(2): 46. DOI:10.3390/jimaging9020046.

[3] GAO B, TONG J, CHEN X, 等. DFIR-DETR: Frequency Domain Enhancement and Dynamic Feature Aggregation for Cross-Scene Small Object Detection[J].

[4] SABERIRONAGHI A, REN J, EL-GINDY M, 等. Defect Detection Methods for Industrial Products Using Deep Learning Techniques: A Review[J/OL].

Algorithms, 2023, 16(2) [2026-01-19].

<https://www.mdpi.com/1999-4893/16/2/95>. DOI:10.3390/a16020095.

[5] SHI Z, HU J, REN J, 等. HS-FPN: High Frequency and Spatial Perception FPN for Tiny Object Detection[A/OL]. arXiv, 2025[2026-02-07].

<http://arxiv.org/abs/2412.10116>. DOI:10.48550/arXiv.2412.10116.

[6] SHI Z, HU J, REN J, 等. HS-FPN: High Frequency and Spatial Perception FPN for Tiny Object Detection[A/OL]. arXiv, 2025[2026-02-07].

<http://arxiv.org/abs/2412.10116>. DOI:10.48550/arXiv.2412.10116.

[7] ZUO Z, DONG J, GAO Y, 等. HyperDefect-YOLO: Enhance YOLO with HyperGraph Computation for Industrial Defect Detection[A/OL]. arXiv, 2024[2026-02-07].

<http://arxiv.org/abs/2412.03969>. DOI:10.48550/arXiv.2412.03969.

[8] ZHANG Z, ZHOU M, WAN H, 等. IDD-Net: Industrial defect detection method based on Deep-Learning[J/OL]. Engineering Applications of Artificial

Intelligence, 2023, 123: 106390. DOI:10.1016/j.engappai.2023.106390.

[9] ZOPH B, CUBUK E D, GHIASI G, 等. Learning Data Augmentation Strategies for Object Detection[A/OL]. arXiv, 2019[2026-02-22].

<http://arxiv.org/abs/1906.11172>. DOI:10.48550/arXiv.1906.11172.

[10] KIM I, KIM Y, KIM S. Learning Loss for Test-Time Augmentation[A/OL].

arXiv, 2020[2026-02-22]. <http://arxiv.org/abs/2010.11422>.

DOI:10.48550/arXiv.2010.11422.

- [11] SUN J, ZHANG Y. Research on Steel Surface Defect Detection Algorithm Based on YOLOv12[J]. 2025, 33(8).
- [12] TARIQ M F, JAVED M A. Small Object Detection with YOLO: A Performance Analysis Across Model Versions and Hardware[A/OL]. arXiv, 2025[2026-02-07]. <http://arxiv.org/abs/2504.09900>. DOI:10.48550/arXiv.2504.09900.
- [13] WANG P, ZHAO J. SOD-YOLO: Enhancing YOLO-Based Detection of Small Objects in UAV Imagery[A/OL]. arXiv, 2025[2026-02-07]. <http://arxiv.org/abs/2507.12727>. DOI:10.48550/arXiv.2507.12727.
- [14] KHALILI B, SMYTH A W. SOD-YOLOv8 -- Enhancing YOLOv8 for Small Object Detection in Traffic Scenes[A/OL]. arXiv, 2024[2026-02-07]. <http://arxiv.org/abs/2408.04786>. DOI:10.48550/arXiv.2408.04786.
- [15] XIE Y, HU W, XIE S, 等. Surface Defect Detection Algorithm Based on Feature-Enhanced YOLO[J/OL]. Cognitive Computation, 2023, 15(2): 565-579. DOI:10.1007/s12559-022-10061-z.
- [16] LI Y, FAN B, ZHANG W, 等. TireNet: A high recall rate method for practical application of tire defect type classification[J/OL]. Future Generation Computer Systems, 2021, 125: 1-9. DOI:10.1016/j.future.2021.06.009.
- [17] DAMACHARLA P, V A R M, RINGENBERG J, 等. TLU-Net: A Deep Learning Approach for Automatic Steel Surface Defect Detection[A/OL]. arXiv, 2021[2026-02-07]. <http://arxiv.org/abs/2101.06915>. DOI:10.48550/arXiv.2101.06915.
- [18] KIMURA M. Understanding Test-Time Augmentation[A/OL]. arXiv, 2024[2026-02-22]. <http://arxiv.org/abs/2402.06892>. DOI:10.48550/arXiv.2402.06892.
- [19] YASEEN M. What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector[A/OL]. arXiv, 2024[2026-02-07].

<https://arxiv.org/abs/2408.15857>. DOI:10.48550/ARXIV.2408.15857.

[20] YASEEN M. What is YOLOv8: An In-Depth Exploration of the Internal Features of the Next-Generation Object Detector[A/OL]. arXiv, 2024[2026-02-07]. <http://arxiv.org/abs/2408.15857>. DOI:10.48550/arXiv.2408.15857.

[21] CHOU P H, WANG C C, MAO W L. YOLO-Based Defect Detection for Metal Sheets[A/OL]. (2025-10-03) [2026-02-07]. <http://arxiv.org/abs/2509.25659>. DOI:10.1109/IST63414.2024.10759237.

[22] HUSSAIN M. YOLO-v1 to YOLO-v8, the Rise of YOLO and Its Complementary Nature toward Digital Manufacturing and Industrial Defect Detection[J/OL]. Machines, 2023, 11(7) [2026-01-19]. <https://www.mdpi.com/2075-1702/11/7/677>. DOI:10.3390/machines11070677.

[23] HIDAYATULLAH P, SYAKRANI N, SHOLAHUDDIN M R, 等. YOLOv8 to YOLO11: A Comprehensive Architecture In-depth Comparative Review[J].

[24] SHI W, DAI J, LI C, 等. YOLOv11-EMD: An Enhanced Object Detection Algorithm Assisted by Multi-Stage Transfer Learning for Industrial Steel Surface Defect Detection[J/OL]. Mathematics, 2025, 13(17): 2769. DOI:10.3390/math13172769.

毕业设计（论文）进度安排：

序号	毕业设计（论文）各阶段内容	时间安排	备注
1	查阅相关文献，明确研究方向与技术路线，完成开题报告	2026.2.1-2026.3.1	
2	搭建实验环境，完成数据集整理与 Baseline 模型训练	2026.3.1-2026.3.15	
3	进行模型训练策略改进实验，分析性能变化	2026.3.15-2026.3.31	
4	构建半监督学习流程，完成伪	2026.4.1-2026.4.15	

	标签生成与对比实验		
5	设计并实现交通零部件缺陷检测系统原型	2026.4.15-2026.4.30	
6	整理实验结果，撰写毕业论文	2026.5.1-2026.5.15	
7	修改论文，准备答辩材料，完成毕业设计答辩	2026.5.15-2026.5.31	
指导教师意见：			

指导教师（审核签名）：

吴睿智

审核日期：2026 年 2

月 27 日

2025 年 9 月

第 1 --- 2 周

指导日期	2025.9.17	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 与导师沟通毕设方向，确定围绕深度学习目标检测开展交通零部件缺陷检测研究。 2. 收集工业缺陷检测、钢材表面缺陷检测和 YOLO 系列算法相关资料。		
存在问题	对交通零部件缺陷检测的实际场景和缺陷类别理解还不够深入。		
下一步工作安排	1. 阅读工业视觉检测相关综述。 2. 梳理 NEU-DET 等公开数据集的类别、标注格式和适用范围。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期: 2025 年 9

月 17 日

第 2 --- 3 周

指导日期	2025.9.25	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 学习目标检测基本流程，掌握 Precision、Recall、mAP 等评价指标。 2. 调研 YOLOv5、YOLOv8 等主流单阶段检测算法。 3. 初步下载并查看 NEU-DET 数据集结构。		
存在问题	对 YOLOv8 网络结构、损失函数组成以及训练配置理解还不够系统。		
下一步工作安排	1. 重点学习 YOLOv8 模型结构和训练参数。 2. 完成数据集格式转换和样例可视化脚本。		
指导教师 (组)意见			

指导教师(签字):

吴睿智

指导日期: 2025 年 9

月 25 日

第 5 --- 6 周

指导日期	2025.10.15	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 完成 YOLOv8 基础训练流程测试，能够正常读取数据并输出检测结果。 2. 初步记录训练过程中的 loss 变化和验证集指标。 3. 与导师讨论后确定基线模型、训练策略优化和半监督伪标签实验为主要研究内容。		
存在问题	初始模型在部分小尺度缺陷上存在漏检，类别间检测效果差异较明显。		
下一步工作安排	1. 继续完成 Baseline 完整训练。 2. 分析不同类别的误检、漏检样例。		
指导教师(组)意见			

指导教师（签字）：

吴睿智

指导日期： 2025 年

10 月 15 日

第 6 --- 7 周

指导日期	2025.10.23	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 完成 Baseline 模型训练，整理各类别 Precision、Recall 和 mAP 指标。 2. 对典型检测结果进行可视化，分析裂纹、划痕等缺陷的识别情况。		
存在问题	模型对背景纹理复杂、缺陷边界模糊的图像识别稳定性不足。		
下一步工作安排	1. 尝试调整输入尺寸、数据增强和学习率策略。 2. 对比不同训练配置对模型指标的影响。		
指导教师(组)意见			

指导教师（签字）：

吴睿智

指导日期： 2025 年

10 月 23 日

第 7 --- 8 周

指导日期	2025.10.30	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 开展学习率、batch size、训练轮次等超参数对比实验。 2. 分析不同数据增强方式对检测性能的影响。 3. 初步确定一组较稳定的训练配置。		
存在问题	实验组数较多，结果记录和命名不够规范，后续复现实验存在困难。		
下一步工作安排	1. 统一实验目录、配置文件和结果命名规则。 2. 补充实验日志，保证每组实验可追踪。		
指导教师 (组)意见			

指导教师（签字）：

吴睿智

指导日期： 2025 年

10 月 30 日

第 9 --- 10 周

指导日期	2025.11.12	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 完成多组训练策略优化实验。 2. 对比 Baseline 与改进配置下的检测指标变化。 3. 开始撰写开题报告中项目背景与研究现状部分。		
存在问题	对半监督目标检测相关文献掌握不足，伪标签生成与筛选策略还不清晰。		
下一步工作安排	1. 阅读半监督目标检测和伪标签学习相关论文。 2. 设计有标签/无标签数据划分方案。		
指导教师 (组)意见			

指导教师（签字）：

吴睿智

指导日期： 2025 年

11 月 12 日

第 13 --- 14 周

指导日期	2025.12.11	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 根据导师意见修改开题报告，完善技术路线和可行性分析。 2. 整理主要参考文献，规范文献格式。 3. 准备开题答辩 PPT。		
存在问题	部分参考文献与课题关联度不够强，文献综述的层次还需优化。		
下一步工作安排	1. 补充工业缺陷检测、YOLO 改进、半监督学习方向的核心文献。 2. 继续完善答辩材料。		
指导教师 (组)意见			

指导教师（签字）： 吴睿智

指导日期： 2025 年

12 月 11 日

第 15 --- 16 周

指导日期	2025.12.24	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 完成开题报告定稿和开题答辩准备。 2. 对 Baseline 训练代码进行整理，封装数据加载、训练和评估脚本。 3. 初步实现伪标签生成脚本。		
存在问题	伪标签阈值设置缺乏依据，低置信度预测容易引入噪声。		
下一步工作安排	1. 设计不同置信度阈值的对比实验。 2. 统计伪标签数量、类别分布和可视化质量。		
指导教师 (组)意见			

指导教师（签字）：

吴睿智

指导日期： 2025 年

12 月 24 日

第 17 --- 18 周

指导日期	2026.1.8	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 完成 Seed 模型训练，并对无标签数据生成初版伪标签。 2. 实现伪标签筛选与 YOLO 格式导出。 3. 构建真实标注数据与伪标注数据混合训练集。		
存在问题	伪标签中存在误检框和定位偏差，可能影响后续模型训练稳定性。		
下一步工作安排	1. 引入置信度阈值和类别分布约束。 2. 对不同筛选策略下的伪标签质量进行对比。		
指导教师 (组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 1

月 8 日

第 19 --- 20 周

指导日期	2026.1.22	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 完成多组伪标签阈值实验。 2. 比较 10%、20%有标签比例下半监督训练效果。 3. 整理阶段性实验结果，形成问题清单。		
存在问题	部分半监督实验提升不稳定，伪标签噪声在小样本类别上更明显。		
下一步工作安排	1. 调整伪标签筛选策略，尝试更严格阈值和多阶段更新。 2. 分析各类别指标变化原因。		
指导教师 (组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 1

月 22 日

第 23 --- 24 周

指导日期	2026.2.24	指导地点	线上
参加人	梁曦霖、吴睿智		
工作进展	1. 优化训练脚本结构，提高实验复现性。 2. 完成部分半监督混合训练实验。 3. 开始撰写论文理论基础和相关技术章节。		
存在问题	实验结果与预期存在差异，需要进一步区分数据划分、阈值设置和训练轮次的影响。		
下一步工作安排	1. 固定随机种子和数据划分，重新运行关键实验。 2. 完善论文中 YOLOv8 与半监督学习原理介绍。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 2

月 24 日

第 25 --- 26 周

指导日期	2026.3.5	指导地点	线上
参加人	梁曦霖、吴睿智		
工作进展	1. 完成固定划分下的 Baseline、Seed 模型和伪标签训练对比。 2. 整理不同有标签比例下的 mAP 变化。 3. 初步绘制性能对比图。		
存在问题	对实验结果的解释还不够充分，缺少典型可视化案例支撑。		
下一步工作安排	1. 收集误检、漏检和成功检测样例。 2. 结合可视化结果分析半监督策略的有效性与局限性。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 3

月 5 日

第 27 --- 28 周

指导日期	2026.3.19	指导地点	线上
参加人	梁曦霖、吴睿智		
工作进展	1. 完成伪标签阈值、训练轮次和数据比例变化实验。 2. 补充典型检测结果可视化图。 3. 开始设计缺陷检测 Web 系统原型。		
存在问题	模型推理结果与前端展示的数据格式衔接还不够清晰。		
下一步工作安排	1. 封装模型推理接口。 2. 设计图像上传、检测结果返回和框图可视化流程。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 3

月 19 日

第 29 --- 30 周

指导日期	2026.4.2	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 基于 Flask 完成后端推理接口初版。 2. 实现图像上传、模型推理和结果图片保存功能。 3. 撰写论文系统设计章节初稿。		
存在问题	前端页面交互较简单，检测结果展示效果不够直观。		
下一步工作安排	1. 完善前端页面布局 and 结果可视化。 2. 增加检测类别、置信度等结果信息展示。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 4

月 2 日

第 33 --- 34 周

指导日期	2026.4.29	指导地点	线上
参加人	梁曦霖、吴睿智		
工作进展	1. 完成论文初稿整体撰写。 2. 按学校模板检查目录、图表、参考文献和页眉页脚格式。 3. 整理代码和实验数据。		
存在问题	论文格式仍有细节问题，部分图表标题和正文引用不够规范。		
下一步工作安排	1. 根据学院格式要求逐项修改。 2. 将论文初稿提交导师审阅并等待反馈。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期： 2026 年 4

月 29 日

第 35 --- 36 周

指导日期	2026.5.14	指导地点	线上
参加人	梁曦霖、吴睿智		
工作进展	1. 根据导师意见完成论文第一轮修改。 2. 强化实验结果分析，补充半监督方法局限性讨论。 3. 准备初稿提交所需材料。		
存在问题	论文前后逻辑衔接仍需加强，系统实现与算法实验之间的关系需要说明得更清楚。		
下一步工作安排	1. 调整论文结构，增强章节之间的承接。 2. 准备答辩 PPT 和系统演示材料。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期： 2026 年 5

月 14 日

第 37 --- 38 周

指导日期	2026.5.27	指导地点	逸夫教学楼
参加人	梁曦霖、吴睿智		
工作进展	1. 根据最终评阅意见修改论文格式和表述。 2. 完成答辩 PPT、系统演示截图和相关提交材料整理。 3. 对工作日志、任务书、开题报告和外文译文等材料进行汇总检查。		
存在问题	仍需重点检查论文细节格式、图表引用和提交材料完整性。		
下一步工作安排	1. 对照模板完成最终格式检查。 2. 准备答辩陈述和可能问题回答，按要求提交最终材料。		
指导教师(组)意见			

指导教师(签字):

吴睿智

指导日期: 2026 年 5

月 27 日

题 目：_____基于深度学习的交通零部件缺陷检测系统设计与实现

学院：软件学院 专业：软件工程 学生姓名：梁曦霖 学号：22301094

一、外文原文

外文原文与译文：要求翻译的原文是论文的参考文献，或与论文密切相关的资料，原文应不少于 10000 字符。

（内容宋体小四首行缩进 2 字符，外文和数字字体为“Times New Roman”，行间距为固定值 20 磅。各学院可以根据外文来源适当调整外文原文格式要求。）

以下为论文核心 CBAM 算法的关键文献 CBAM Convolutional Block Attention Module 的翻译

CBAM: Convolutional Block Attention Module

Sanghyun Woo*¹, Jongchan Park*[†]², Joon-Young Lee³, and In So Kweon¹

1

Korea Advanced Institute of Science and Technology, Daejeon, Korea

{shwoo93, iskweon77}@kaist.ac.kr

2

Lunit Inc., Seoul, Korea

jcpark@lunit.io

3

Adobe Research, San Jose, CA, USA

jolee@adobe.com

Abstract. We propose Convolutional Block Attention Module (CBAM), a simple yet effective attention module for feed-forward convolutional neural networks. Given an intermediate feature map, our module sequentially infers attention maps along two separate dimensions, channel and spatial, then the attention maps are multiplied to the input feature map for adaptive feature refinement. Because CBAM is a lightweight and general module, it can be integrated into any CNN architectures seamlessly with negligible overheads and is end-to-end trainable along with base CNNs. We validate our CBAM through extensive experiments on ImageNet-1K, MS COCO detection, and VOC 2007 detection datasets. Our experiments show consistent improvements in classification and detection performances with various models, demonstrating the wide applicability of CBAM. The code and models will be publicly available.

Keywords: Object recognition, attention mechanism, gated convolu

tion

1 Introduction

Convolutional neural networks (CNNs) have significantly pushed the performance of vision tasks [1–3] based on their rich representation power. To enhance performance of CNNs, recent researches have mainly investigated three important factors of networks: depth, width, and cardinality.

From the LeNet architecture [4] to Residual-style Networks [5–8] so far, the network has become deeper for rich representation. VGGNet [9] shows that stacking blocks with the same shape gives fair results. Following the same spirit, ResNet [5] stacks the same topology of residual blocks along with skip connection to build an extremely deep architecture. GoogLeNet [10] shows that width is another important factor to improve the performance of a model. Zagoruyko and Komodakis [6] propose to increase the width of a network based on the ResNet architecture. They have shown that a 28-layer ResNet with increased

*Both authors have equally contributed.

†The work was done while the author was at KAIST.

arXiv:1807.06521v2 [cs.CV] 18 Jul 20182 Woo, Park, Lee, Kweon

Channel

Attention

Module

Spatial

Attention

Module

Convolutional Block Attention Module

Input Feature

Refined Feature

Fig. 1: The overview of CBAM. The module has two sequential sub-modules: channel and spatial. The intermediate feature map is adaptively refined through our module (CBAM) at every convolutional block of deep networks.

width can outperform an extremely deep ResNet with 1001 layers on the CIFAR benchmarks. Xception [11] and ResNeXt [7] come up with to increase the cardinality of a network. They empirically show that cardinality not only saves the total number of parameters but also results in stronger representation power than the other two factors: depth and width.

Apart from these factors, we investigate a different aspect of the architecture design, attention. The significance of attention has been studied extensively in the previous literature [12–17]. Attention not only tells where to focus, it also improves the representation of interests. Our goal is to increase representation power by using attention mechanism: focusing on important features and suppressing unnecessary ones. In this paper, we propose a new network module, named “Convolutional Block Attention Module”. Since convolution operations extract informative features by blending cross-channel and spatial information together, we adopt our module to emphasize meaningful features along those two principal dimensions: channel and spatial axes. To achieve this, we sequentially apply channel and spatial attention modules (as shown in Fig. 1), so that each of the branches can learn ‘what’ and ‘where’ to attend in the channel and spatial axes respectively. As a result, our module efficiently helps the information flow within the network by learning which information to emphasize or suppress. In the ImageNet-1K dataset, we obtain accuracy improvement from various baseline networks by plugging our tiny module, revealing the efficacy of CBAM. We visualize trained models using the grad-CAM [18] and observe that CBAM enhanced networks focus on target objects more properly than their baseline networks. Taking this into account, we conjecture that the performance boost comes from accurate attention and noise reduction of irrelevant clutters. Finally, we validate performance improvement of object detection on the MS COCO and the VOC 2007 datasets, demonstrating a wide applicability of CBAM. Since we have carefully designed our module to be light-weight, the overhead of parameters and computation is negligible in most cases.

Contribution. Our main contribution is three-fold.

1. We propose a simple yet effective attention module (CBAM) that can be widely applied to boost representation power of CNNs.
2. We validate the effectiveness of our attention module through extensive ablation studies.
3. We verify that performance of various networks is greatly improved on the multiple benchmarks (ImageNet-1K, MS COCO, and VOC 2007) by plugging our light-weight module.

2 Related Work

Network engineering. “Network engineering” has been one of the most impor

tant vision research, because well-designed networks ensure remarkable performance improvement in various applications. A wide range of architectures has been proposed since the successful implementation of a large-scale CNN [19]. An intuitive and simple way of extension is to increase the depth of neural networks [9]. Szegedy et al. [10] introduce a deep Inception network using a multi-branch architecture where each branch is customized carefully. While a naive increase in depth comes to saturation due to the difficulty of gradient propagation, ResNet [5] proposes a simple identity skip-connection to ease the optimization issues of deep networks. Based on the ResNet architecture, various models such as WideResNet [6], Inception-ResNet [8], and ResNeXt [7] have been developed. WideResNet [6] proposes a residual network with a larger number of convolutional filters and reduced depth. PyramidNet [20] is a strict generalization of WideResNet where the width of the network gradually increases. ResNeXt [7] suggests to use grouped convolutions and shows that increasing the cardinality leads to better classification accuracy. More recently, Huang et al. [21] propose a new architecture, DenseNet. It iteratively concatenates the input features with the output features, enabling each convolution block to receive raw information from all the previous blocks. While most of recent network engineering methods mainly target on three factors depth [19, 9, 10, 5], width [10, 22, 6, 8], and cardinality [7, 11], we focus on the other aspect, ‘attention’, one of the curious facets of a human visual system.

Attention mechanism. It is well known that attention plays an important role in human perception [23–25]. One important property of a human visual system is that one does not attempt to process a whole scene at once. Instead, humans exploit a sequence of partial glimpses and selectively focus on salient parts in order to capture visual structure better [26].

Recently, there have been several attempts [27, 28] to incorporate attention processing to improve the performance of CNNs in large-scale classification tasks.

Wang et al. [27] propose Residual Attention Network which uses an encoder decoder style attention module. By refining the feature maps, the network not only performs well but is also robust to noisy inputs. Instead of directly computing the 3d attention map, we decompose the process that learns channel attention and spatial attention separately. The separate attention generation process for 3D feature map has much less computational and parameter over-4 Woo, Park, Lee,

Kweon

head, and therefore can be used as a plug-and-play module for pre-existing base CNN architectures.

More close to our work, Hu et al. [28] introduce a compact module to exploit the inter-channel relationship. In their Squeeze-and-Excitation module, they use global average-pooled features to compute channel-wise attention. However, we show that those are suboptimal features in order to infer fine channel attention, and we suggest to use max-pooled features as well. They also miss the spatial attention, which plays an important role in deciding ‘where’ to focus as shown in [29]. In our CBAM, we exploit both spatial and channel-wise attention based on an efficient architecture and empirically verify that exploiting both is superior to using only the channel-wise attention as [28]. Moreover, we empirically show that our module is effective in detection tasks (MS-COCO and VOC). Especially, we achieve state-of-the-art performance just by placing our module on top of the existing one-shot detector [30] in the VOC2007 test set.

3 Convolutional Block Attention Module

Given an intermediate feature map $F \in \mathbb{R}^{C \times H \times W}$ as input, CBAM sequentially infers a 1D channel attention map $M_c \in \mathbb{R}^{C \times 1 \times 1}$ and a 2D spatial attention map $M_s \in \mathbb{R}^{1 \times H \times W}$ as illustrated in Fig. 1. The overall attention process can be summarized as:

$$\begin{aligned} F_0 &= M_c(F) \otimes F, \\ F_{00} &= M_s(F_0) \otimes F_0, \end{aligned} \quad (1)$$

where $\otimes$ denotes element-wise multiplication. During multiplication, the attention values are broadcasted (copied) accordingly: channel attention values are broadcasted along the spatial dimension, and vice versa. F_{00} is the final refined output. Fig. 2 depicts the computation process of each attention map. The following describes the details of each attention module.

Channel attention module. We produce a channel attention map by exploiting the inter-channel relationship of features. As each channel of a feature map is considered as a feature detector [31], channel attention focuses on ‘what’ is meaningful given an input image. To compute the channel attention efficiently, we squeeze the spatial dimension of the input feature map. For aggregating spatial information, average-pooling has been commonly adopted so far. Zhou et al.

[32] suggest to use it to learn the extent of the target object effectively and Hu et al. [28] adopt it in their attention module to compute spatial statistics. Beyond the previous works, we argue that max-pooling gathers another important clue about distinctive object features to infer finer channel-wise attention. Thus, we use both average-pooled and max-pooled features simultaneously. We empirically confirmed that exploiting both features greatly improves representation power of networks rather than using each independently (see Sec. 4.1), showing the effectiveness of our design choice. We describe the detailed operation below.

Convolutional Block Attention Module 5

MaxPool
AvgPool
Channel Attention
MC
Channel Attention Module
[MaxPool, AvgPool]
Spatial Attention
MS
Spatial Attention Module
Input feature F
Channel-refined
feature F'
Shared MLP
conv
layer

Fig. 2: Diagram of each attention sub-module. As illustrated, the channel sub-module utilizes both max-pooling outputs and average-pooling outputs with a shared network; the spatial sub-module utilizes similar two outputs that are pooled along the channel axis and forward them to a convolution layer.

We first aggregate spatial information of a feature map by using both average pooling and max-pooling operations, generating two different spatial context descriptors: F_c^{avg} and F_c^{max} , which denote average-pooled features and max-pooled features respectively. Both descriptors are then forwarded to a shared network to produce our channel attention map $M_c \in \mathbb{R}^{C \times 1 \times 1}$. The shared network is composed of multi-layer perceptron (MLP) with one hidden layer. To reduce

parameter overhead, the hidden activation size is set to $R \times C/r \times 1 \times 1$, where r is the reduction ratio. After the shared network is applied to each descriptor, we merge the output feature vectors using element-wise summation. In short, the channel attention is computed as:

$$\begin{aligned} \text{Mc}(F) &= \sigma(\text{MLP}(\text{AvgPool}(F)) + \text{MLP}(\text{MaxPool}(F))) \\ &= \sigma(W1(W0(F \text{ c avg})) + W1(W0(F \text{ c max}))), \end{aligned} \quad (2)$$

where σ denotes the sigmoid function, $W0 \in R \times C/r \times C$, and $W1 \in R \times C \times C/r$. Note that the MLP weights, $W0$ and $W1$, are shared for both inputs and the ReLU activation function is followed by $W0$.

Spatial attention module. We generate a spatial attention map by utilizing the inter-spatial relationship of features. Different from the channel attention, the spatial attention focuses on ‘where’ is an informative part, which is complementary to the channel attention. To compute the spatial attention, we first apply average-pooling and max-pooling operations along the channel axis and concatenate them to generate an efficient feature descriptor. Applying pooling operations along the channel axis is shown to be effective in highlighting informative regions [33]. On the concatenated feature descriptor, we apply a convolution6 Woo, Park, Lee,

Kweon

Channel attention

ResBlock + CBAM

Next

conv blocks

Previous

conv blocks

F

Spatial attention

conv

MC

MS

F’

F’’

Fig. 3: CBAM integrated with a ResBlock in ResNet[5]. This figure shows the exact position of our module when integrated within a ResBlock. We apply

CBAM on the convolution outputs in each block.

layer to generate a spatial attention map $M_s(F) \in \mathbb{R}^{H \times W}$ which encodes where to emphasize or suppress. We describe the detailed operation below.

We aggregate channel information of a feature map by using two pooling operations, generating two 2D maps: $F_s^{avg} \in \mathbb{R}^{1 \times H \times W}$ and $F_s^{max} \in \mathbb{R}^{1 \times H \times W}$.

Each denotes average-pooled features and max-pooled features across the channel. Those are then concatenated and convolved by a standard convolution layer, producing our 2D spatial attention map. In short, the spatial attention is computed as:

$$\begin{aligned} M_s(F) &= \sigma(f_{7 \times 7}([\text{AvgPool}(F); \text{MaxPool}(F)])) \\ &= \sigma(f_{7 \times 7}([F_s^{avg}; F_s^{max}])), \end{aligned} \quad (3)$$

where σ denotes the sigmoid function and $f_{7 \times 7}$ represents a convolution operation with the filter size of 7×7 .

Arrangement of attention modules. Given an input image, two attention modules, channel and spatial, compute complementary attention, focusing on ‘what’ and ‘where’ respectively. Considering this, two modules can be placed in a parallel or sequential manner. We found that the sequential arrangement gives a better result than a parallel arrangement. For the arrangement of the sequential process, our experimental result shows that the channel-first order is slightly better than the spatial-first. We will discuss experimental results on network engineering in Sec. 4.1.

4 Experiments

We evaluate CBAM on the standard benchmarks: ImageNet-1K for image classification; MS COCO and VOC 2007 for object detection. In order to perform better apple-to-apple comparisons, we reproduced all the evaluated networks [5–7, 34, 28] in the PyTorch framework [35] and report our reproduced results in the whole experiments.

To thoroughly evaluate the effectiveness of our final module, we first perform extensive ablation experiments. Then, we verify that CBAM outperforms all the Convolutional Block

Attention Module 7

baselines without bells and whistles, demonstrating the general applicability of CBAM across different architectures as well as different tasks. One can seamlessly integrate CBAM in any CNN architectures and jointly train the combined

CBAM-enhanced networks. Fig. 3 shows a diagram of CBAM integrated with a ResBlock in ResNet [5] as an example.

4.1 Ablation studies

In this subsection, we empirically show the effectiveness of our design choice. For this ablation study, we use the ImageNet-1K dataset and adopt ResNet-50 [5] as the base architecture. The ImageNet-1K classification dataset [1] consists of 1.2 million images for training and 50,000 for validation with 1,000 object classes. We adopt the same data augmentation scheme with [5, 36] for training and apply a single-crop evaluation with the size of 224×224 at test time. The learning rate starts from 0.1 and drops every 30 epochs. We train the networks for 90 epochs. Following [5, 36, 37], we report classification errors on the validation set.

Our module design process is split into three parts. We first search for the effective approach to computing the channel attention, then the spatial attention. Finally, we consider how to combine both channel and spatial attention modules. We explain the details of each experiment below.

Channel attention. We experimentally verify that using both average-pooled and max-pooled features enables finer attention inference. We compare 3 variants of channel attention: average pooling, max pooling, and joint use of both poolings. Note that the channel attention module with an average pooling is the same as the SE [28] module. Also, when using both poolings, we use a shared MLP for attention inference to save parameters, as both of aggregated channel features lie in the same semantic embedding space. We only use channel attention modules in this experiment and we fix the reduction ratio to 16.

Experimental results with various pooling methods are shown in Table 1. We observe that max-pooled features are as meaningful as average-pooled features, comparing the accuracy improvement from the baseline. In the work of SE [28], however, they only exploit the average-pooled features, missing the importance

Description

Parameters GFLOPs Top-1 Error(%) Top-5 Error(%)

ResNet50 (baseline)

25.56M

3.86

24.56

7.50

ResNet50 + AvgPool (SE [28])

25.92M

3.94

23.14

6.70

ResNet50 + MaxPool

25.92M

3.94

23.20

6.83

ResNet50 + AvgPool & MaxPool

25.92M

4.02

22.80

6.52

Table 1: Comparison of different channel attention methods. We observe that using our proposed method outperforms recently suggested Squeeze and Excitation method [28].⁸ Woo, Park, Lee, Kweon

Description

Param. GFLOPs Top-1 Error(%) Top-5 Error(%)

ResNet50 + channel (SE [28])

28.09M

3.860

23.14

6.70

ResNet50 + channel

28.09M

3.860

22.80

6.52

ResNet50 + channel + spatial (1x1 conv, k=3) 28.10M

3.862

22.96

6.64

ResNet50 + channel + spatial (1x1 conv, k=7) 28.10M

3.869

22.90

6.47

ResNet50 + channel + spatial (avg&max, k=3) 28.09M

3.863

22.68

6.41

ResNet50 + channel + spatial (avg&max, k=7) 28.09M

3.864

22.66

6.31

Table 2: Comparison of different spatial attention methods. Using the proposed channel-pooling (i.e. average- and max-pooling along the channel axis) along with the large kernel size of 7 for the following convolution operation performs best.

Description

Top-1 Error(%) Top-5 Error(%)

ResNet50 + channel (SE [28])

23.14

6.70

ResNet50 + channel + spatial

22.66

6.31

ResNet50 + spatial + channel

22.78

6.42

ResNet50 + channel & spatial in parallel

22.95

6.59

Table 3: Combining methods of channel and spatial attention. Using both attention is critical while the best-combining strategy (i.e. sequential, channel-first) further improves the accuracy. of max-pooled features. We argue that max-pooled features which encode the de

gree of the most salient part can compensate the average-pooled features which encode global statistics softly. Thus, we suggest to use both features simultaneously and apply a shared network to those features. The outputs of a shared network are then merged by element-wise summation. We empirically show that our channel attention method is an effective way to push performance further from SE [28] without additional learnable parameters. As a brief conclusion, we use both average- and max-pooled features in our channel attention module with the reduction ratio of 16 in the following experiments.

Spatial attention. Given the channel-wise refined features, we explore an effective method to compute the spatial attention. The design philosophy is symmetric with the channel attention branch. To generate a 2D spatial attention map, we first compute a 2D descriptor that encodes channel information at each pixel over all spatial locations. We then apply one convolution layer to the 2D descriptor, obtaining the raw attention map. The final attention map is normalized by the sigmoid function.

We compare two methods of generating the 2D descriptor: channel pooling using average- and max-pooling across the channel axis and standard 1×1 convolution reducing the channel dimension into 1. In addition, we investigate the effect of a kernel size at the following convolution layer: kernel sizes of 3 and 7.

In the experiment, we place the spatial attention module after the previously Convolutional Block Attention Module 9

designed channel attention module, as the final goal is to use both modules together.

Table 2 shows the experimental results. We can observe that the channel pooling produces better accuracy, indicating that explicitly modeled pooling leads to finer attention inference rather than learnable weighted channel pooling (implemented as 1×1 convolution). In the comparison of different convolution kernel sizes, we find that adopting a larger kernel size generates better accuracy in both cases. It implies that a broad view (i.e. large receptive field) is needed for deciding spatially important regions. Considering this, we adopt the channel pooling method and the convolution layer with a large kernel size to compute spatial attention. In a brief conclusion, we use the average- and max-pooled features across the channel axis with a convolution kernel size of 7 as our spatial attention module.

Arrangement of the channel and spatial attention. In this experiment, we compare three different ways of arranging the channel and spatial attention submodules: sequential channel-spatial, sequential spatial-channel, and parallel use of both attention modules. As each module has different functions, the order may affect the overall performance. For example, from a spatial viewpoint, the channel attention is globally applied, while the spatial attention works locally. Also, it is natural to think that we may combine two attention outputs to build a 3D attention map. In the case, both attentions can be applied in parallel, then the outputs of the two attention modules are added and normalized with the sigmoid function.

Table 3 summarizes the experimental results on different attention arranging methods. From the results, we can find that generating an attention map sequentially infers a finer attention map than doing in parallel. In addition, the channel-first order performs slightly better than the spatial-first order. Note that all the arranging methods outperform using only the channel attention independently, showing that utilizing both attentions is crucial while the best-arranging strategy further pushes performance.

Final module design. Throughout the ablation studies, we have designed the channel attention module, the spatial attention module, and the arrangement of the two modules. Our final module is as shown in Fig. 1 and Fig. 2: we choose average- and max-pooling for both channel and spatial attention module; we use convolution with a kernel size of 7 in the spatial attention module; we arrange the channel and spatial submodules sequentially. Our final module(i.e. ResNet50 + CBAM) achieves top-1 error of 22.66%, which is much lower than SE [28](i.e. ResNet50 + SE), as shown in Table 4.

4.2 Image Classification on ImageNet-1K

We perform ImageNet-1K classification experiments to rigorously evaluate our module. We follow the same protocol as specified in Sec. 4.1 and evaluate our

Kweon

Architecture

Param. GFLOPs Top-1 Error (%) Top-5 Error (%)

ResNet18 [5]

11.69M

1.814

29.60

10.55

ResNet18 [5] + SE [28]

11.78M

1.814

29.41

10.22

ResNet18 [5] + CBAM

11.78M

1.815

29.27

10.09

ResNet34 [5]

21.80M

3.664

26.69

8.60

ResNet34 [5] + SE [28]

21.96M

3.664

26.13

8.35

ResNet34 [5] + CBAM

21.96M

3.665

25.99

8.24

ResNet50 [5]

25.56M

3.858

24.56

7.50

ResNet50 [5] + SE [28]

28.09M

3.860
23.14
6.70
ResNet50 [5] + CBAM
28.09M
3.864
22.66
6.31
ResNet101 [5]
44.55M
7.570
23.38
6.88
ResNet101 [5] + SE [28]
49.33M
7.575
22.35
6.19
ResNet101 [5] + CBAM
49.33M
7.581
21.51
5.69
WideResNet18 [6] (widen=1.5)
25.88M
3.866
26.85
8.88
WideResNet18 [6] (widen=1.5) + SE [28] 26.07M
3.867
26.21
8.47
WideResNet18 [6] (widen=1.5) + CBAM 26.08M
3.868

26.10

8.43

WideResNet18 [6] (widen=2.0)

45.62M

6.696

25.63

8.20

WideResNet18 [6] (widen=2.0) + SE [28] 45.97M

6.696

24.93

7.65

WideResNet18 [6] (widen=2.0) + CBAM 45.97M

6.697

24.84

7.63

ResNeXt50 [7] (32x4d)

25.03M

3.768

22.85

6.48

ResNeXt50 [7] (32x4d) + SE [28]

27.56M

3.771

21.91

6.04

ResNeXt50 [7] (32x4d) + CBAM

27.56M

3.774

21.92

5.91

ResNeXt101 [7] (32x4d)

44.18M

7.508

21.54

5.75

ResNeXt101 [7] (32x4d) + SE [28]

48.96M

7.512

21.17

5.66

ResNeXt101 [7] (32x4d) + CBAM

48.96M

7.519

21.07

5.59

* all results are reproduced in the PyTorch framework.

Table 4: Classification results on ImageNet-1K. Single-crop validation errors are reported.

module in various network architectures including ResNet [5], WideResNet [6], and ResNext [7].

Table 4 summarizes the experimental results. The networks with CBAM outperform all the baselines significantly, demonstrating that the CBAM can generalize well on various models in the large-scale dataset. Moreover, the models with CBAM improve the accuracy upon the one of the strongest method – SE [28] which is the winning approach of the ILSVRC 2017 classification task. It implies that our proposed approach is powerful, showing the efficacy of new pooling method that generates richer descriptor and spatial attention that complements the channel attention effectively.

Fig. 4 depicts the error curves of various networks during ImageNet-1K training. We can clearly see that our method exhibits lowest training and validation error in both error plots. It shows that CBAM has greater ability to improve generalization power of baseline models compared to SE [28].

We also find that the overall overhead of CBAM is quite small in terms of both parameters and computation. This motivates us to apply our proposed module CBAM to the light-weight network, MobileNet [34]. Table 5 summarizes the experimental results that we conducted based on the MobileNet architecture.

We have placed CBAM to two models, basic and capacity-reduced model(i.e. adjusting width multiplier(α) to 0.7). We observe similar phenomenon as shown Convolutional Block

Attention Module 11

(a) ResNet50 [5] (b) MobileNet [34]

Fig. 4: Error curves during ImageNet-1K training. Best viewed in color.

Architecture

Parameters GFLOPs Top-1 Error (%) Top-5 Error (%)

MobileNet [34] $\alpha = 0.7$

2.30M

0.283

34.86

13.69

MobileNet [34] $\alpha = 0.7 + \text{SE}$ [28]

2.71M

0.283

32.50

12.49

MobileNet [34] $\alpha = 0.7 + \text{CBAM}$

2.71M

0.289

31.51

11.48

MobileNet [34]

4.23M

0.569

31.39

11.51

MobileNet [34] + SE [28]

5.07M

0.570

29.97

10.63

MobileNet [34] + CBAM

5.07M

0.576

29.01

9.99

* all results are reproduced in the PyTorch framework.

Table 5: Classification results on ImageNet-1K using the light-weight network, MobileNet [34]. Single-crop validation errors are reported.

in Table 4. CBAM not only boosts the accuracy of baselines significantly but also favorably improves the performance of SE [28]. This shows the great potential of CBAM for applications on low-end devices.

4.3 Network Visualization with Grad-CAM [18]

For the qualitative analysis, we apply the Grad-CAM [18] to different networks using images from the ImageNet validation set. Grad-CAM is a recently proposed visualization method which uses gradients in order to calculate the importance of the spatial locations in convolutional layers. As the gradients are calculated with respect to a unique class, Grad-CAM result shows attended regions clearly. By observing the regions that network has considered as important for predicting a class, we attempt to look at how this network is making good use of features.

We compare the visualization results of CBAM-integrated network (ResNet50 + CBAM) with baseline (ResNet50) and SE-integrated network (ResNet50 + SE).

Fig. 5 illustrate the visualization results. The softmax scores for a target class are also shown in the figure.

In Fig. 5, we can clearly see that the Grad-CAM masks of the CBAM integrated network cover the target object regions better than other methods.

That is, the CBAM-integrated network learns well to exploit information in target object regions and aggregate features from them. Note that target class12 Woo, Park, Lee,

Kweon

P = 0.96340

P=0.87240

P=0.80736

P = 0.19994

P=0.14643

P=0.11857

P = 0.93707

P=0.77550

P=0.65681

P = 0.35248

P=0.25093
P=0.22357
P = 0.87490
P=0.70827
P=0.64185
P = 0.53005
P=0.15367
P=0.14763
P = 0.99085
P=0.97166
P=0.92236
P = 0.59662
P=0.26611
P=0.01176
P = 0.96039
P=0.89962
P=0.58732
P = 0.59790
P=0.14804
P=0.08126
P = 0.84387
P=0.72659
P=0.67128
P = 0.71000
P=0.61595
P=0.56834
P = 0.98482
P=0.96575
P=0.85873
P = 0.90806
P=0.79829
P=0.62856
P = 0.78636
P=0.73723

P=0.68065

P = 0.98567

P=0.92250

P=0.07429

Tailed frog

Toilet tissue

Loudspeaker

Spider web

American egret

Tank

Seawall

Space heater

Croquet ball

Eel

Hammerhead

Eskimo dog

Snow leopard

Boat paddle

Daddy longlegs

School bus

Input

image

ResNet50

ResNet50

+ SE

ResNet50

+ CBAM

Input

image

ResNet50

ResNet50

+ SE

ResNet50

+ CBAM

Fig. 5: Grad-CAM [18] visualization results. We compare the visualization results of CBAM-integrated network (ResNet50 + CBAM) with baseline (ResNet50) and SE-integrated network (ResNet50 + SE). The grad-CAM visualization is calculated for the last convolutional outputs. The ground-truth label is shown on the top of each input image and P denotes the softmax score of each network for the ground-truth class.

Convolutional Block Attention Module 13

Backbone

Detector

mAP@.5 mAP@.75 mAP@[.5, .95]

ResNet50 [5]

Faster-RCNN [41]

46.2

28.1

27.0

ResNet50 [5] + CBAM

Faster-RCNN [41]

48.2

29.2

28.1

ResNet101 [5]

Faster-RCNN [41]

48.4

30.7

29.1

ResNet101 [5] + CBAM Faster-RCNN [41]

50.5

32.6

30.8

* all results are reproduced in the PyTorch framework.

Table 6: Object detection mAP(%) on the MS COCO validation set. We adopt the Faster R-CNN [41] detection framework and apply our module to the base networks. CBAM boosts mAP@[.5, .95] by 0.9 for both baseline networks.

Backbone

Detector

mAP@.5 Parameters (M)

VGG16 [9]

SSD [39]

77.8

26.5

VGG16 [9]

StairNet [30]

78.9

32.0

VGG16 [9]

StairNet [30] + SE [28]

79.1

32.1

VGG16 [9]

StairNet [30] + CBAM

79.3

32.1

MobileNet [34] SSD [39]

68.1

5.81

MobileNet [34] StairNet [30]

70.1

5.98

MobileNet [34] StairNet [30] + SE [28]

70.0

5.99

MobileNet [34] StairNet [30] + CBAM

70.5

6.00

* all results are reproduced in the PyTorch framework.

Table 7: Object detection mAP(%) on the VOC 2007 test set. We adopt

the StairNet [30] detection framework and apply SE and CBAM to the detectors.

CBAM favorably improves all the strong baselines with negligible additional parameters.

scores also increase accordingly. From the observations, we conjecture that the feature refinement process of CBAM eventually leads the networks to utilize given features well.

4.4 MS COCO Object Detection

We conduct object detection on the Microsoft COCO dataset [3]. This dataset involves 80k training images (“2014 train”) and 40k validation images (“2014 val”). The average mAP over different IoU thresholds from 0.5 to 0.95 is used for evaluation. According to [38, 39], we trained our model using all the training images as well as a subset of validation images, holding out 5,000 examples for validation. Our training code is based on [40] and we train the network for 490K iterations for fast performance validation. We adopt Faster-RCNN [41] as our detection method and ImageNet pre-trained ResNet50 and ResNet101 [5] as our baseline networks. Here we are interested in performance improvement by plugging CBAM to the baseline networks. Since we use the same detection method in all the models, the gains can only be attributed to the enhanced representation power, given by our module CBAM. As shown in the Table 6, we observe significant improvements from the baseline, demonstrating generalization performance of CBAM on other recognition tasks.¹⁴ Woo, Park, Lee, Kweon

4.5 VOC 2007 Object Detection

We further perform experiments on the PASCAL VOC 2007 test set. In this experiment, we apply CBAM to the detectors, while the previous experiments (Table 6) apply our module to the base networks. We adopt the StairNet [30] framework, which is one of the strongest multi-scale method based on the SSD [39]. For the experiment, we reproduce SSD and StairNet in our PyTorch platform in order to estimate performance improvement of CBAM accurately and achieve 77.8% and 78.9% mAP@.5 respectively, which are higher than the original accuracy reported in the original papers. We then place SE [28] and CBAM right before every classifier, refining the final features which are composed of up-sampled global features and corresponding local features before the prediction, enforcing model to adaptively select only the meaningful features. We train all the models on the union set of VOC 2007 trainval and VOC 2012 trainval (“07+12”), and evaluate on the VOC 2007 test set. The total number of training epochs is 250. We use a weight decay of 0.0005 and a momentum of 0.9. In all the experiments, the size of the input image is fixed to 300 for the simplicity.

The experimental results are summarized in Table 7. We can clearly see that CBAM improves the accuracy of all strong baselines with two backbone networks. Note that accuracy improvement of CBAM comes with a negligible parameter overhead, indicating that enhancement is not due to a naive capacity increment but because of our effective feature refinement. In addition, the result using the light-weight backbone network [34] again shows that CBAM can be an interesting method to low-end devices.

5 Conclusion

We have presented the convolutional bottleneck attention module (CBAM), a new approach to improve representation power of CNN networks. We apply attention-based feature refinement with two distinctive modules, channel and spatial, and achieve considerable performance improvement while keeping the overhead small. For the channel attention, we suggest to use the max-pooled features along with the average-pooled features, leading to produce finer attention than SE [28]. We further push the performance by exploiting the spatial attention. Our final module (CBAM) learns what and where to emphasize or suppress and refines intermediate features effectively. To verify its efficacy, we conducted extensive experiments with various state-of-the-art models and confirmed that CBAM outperforms all the baselines on three different benchmark datasets: ImageNet-1K, MS COCO, and VOC 2007. In addition, we visualize how the module exactly infers given an input image. Interestingly, we observed that our module induces the network to focus on target object properly. We hope CBAM become an important component of various network architectures.

二、译文

标题与译文格式与论文格式要求相同。插图内文字及图名也译成中文

CBAM: 卷积块注意力模块

禹相铉*1、朴钟灿*†2、李俊英 3、权仁昭 1

1

韩国科学技术院，大田，韩国

{shwoo93, iskweon77}@kaist.ac.kr

2

韩国首尔 Lunit 公司

jcpark@lunit.io

3

Adobe 研究院，美国加利福尼亚州圣何塞

jolee@adobe.com

摘要：我们提出了一种卷积块注意力模块（CBAM），

一种简单而有效的用于前馈卷积的注意力模块

神经网络。给定一个中间特征图，我们的模块会……

按顺序推断沿两个独立维度（通道）的注意力图。

然后，将注意力图与空间特征相乘，并将注意力图与输入特征相乘。

用于自适应特征细化的地图。因为 CBAM 是一种轻量级且

通用模块，可集成到任何 CNN 架构中

几乎无需额外开销，并且可进行端到端培训，以及

我们通过对基础 CNN 的大量实验验证了我们的 CBAM。

ImageNet-1K、MS COCO 检测和 VOC 2007 检测数据集。

我们的实验表明，分类和去污能力均有持续提升。

针对各种型号的防护性能进行了测试，展示了其广泛的适用性

CBAM 的可扩展性。代码和模型将公开提供。

关键词：物体识别，注意力机制，门控卷积

tion

1 引言

卷积神经网络（CNN）显著提升了神经网络的性能。

基于其丰富的表征能力，视觉任务的管理[1-3]。为了实现

为了提高卷积神经网络（CNN）的性能，近期的研究主要集中在三个方面。

网络的重要因素：深度、宽度和基数。

从 LeNet 架构 [4] 到残差式网络 [5 - 8]，迄今为止，

为了实现更丰富的表示，网络变得更深。VGGNet [9] 展示了堆栈

使用形状相同的积木可以获得公平的结果。遵循同样的原则，

ResNet [5] 堆叠了相同拓扑结构的残差块以及跳跃连接

构建极其深的架构。GoogLeNet [10] 表明宽度

是提升模型性能的另一个重要因素。扎戈鲁伊科

Komodakis [6] 提出基于以下方法增加网络宽度：

ResNet 架构。他们已经证明，具有增强功能的 28 层 ResNet

*两位作者贡献相同。

†该作品是作者在韩国科学技术院（KAIST）工作期间完成的。

arXiv:1807.06521v2 [cs.CV] 2018 年 7 月 18 日 Woo, Park, Lee, Kweon

渠道

注意力

模块

空间

注意力

模块

卷积块注意力模块

输入功能

精细化功能

图 1：CBAM 概览。该模块包含两个顺序执行的子模块：

通道和空间。中间特征图通过以下方式自适应地细化：

我们的模块（CBAM）应用于深度网络的每个卷积块。

在 CI 测试中，宽度可以超越具有 1001 层的超深 ResNet 模型。

FAR 基准测试。Xception [11] 和 ResNeXt [7] 提出了提高 FAR 的方法。

网络的基数。他们通过实证研究表明，基数不仅可以节省

参数总数虽然增加了，但也带来了更强的表征能力。

比其他两个因素（深度和宽度）更重要。

除了这些因素之外，我们还研究了建筑的另一个方面。

设计、注意力。注意力的重要性已在……中得到广泛研究。

前文[12-17]指出，注意力不仅告诉我们应该关注什么，而且

提高利益代表度。我们的目标是提高代表性。

利用注意力机制来增强：关注重要特征和支持

按下不必要的按钮。在本文中，我们提出了一种新的网络模块，

名为“卷积块注意力模块”。由于卷积运算

通过融合跨通道和空间信息提取信息特征

我们共同采用我们的模块来强调这两个方面的重要特征。

主要维度：通道轴和空间轴。为了实现这一点，我们依次……

应用通道和空间注意力模块（如图 1 所示），以便每个

各个分支可以学习在频道和空间中“关注什么”和“关注哪里”。

分别对应各个轴。因此，我们的模块能够有效地帮助信息流。

在网络中，通过学习应该强调或抑制哪些信息来发挥作用。

在 ImageNet-1K 数据集上，我们通过各种方法获得了准确率的提升。

通过插入我们的小型模块来构建基线网络，揭示了 CBAM 的有效性。

我们使用 grad-CAM [18] 可视化训练好的模型，并观察到 CBAM

增强型网络比基线网络更能准确地聚焦目标对象。

网络。考虑到这一点，我们推测性能提升

源于精准的注意力集中和对无干扰信息的降噪处理。最后，

我们验证了目标检测在 MS COCO 数据集上的性能提升，

VOC 2007 数据集表明 CBAM 具有广泛的适用性。由于我们

我们精心设计了我们的模块，使其轻量级，参数开销很小。

在大多数情况下，计算量可以忽略不计。

贡献。我们的主要贡献体现在三个方面。

1. 我们提出了一种简单而有效的注意力模块（CBAM），它可以是

广泛应用于提升卷积神经网络（CNN）的表征能力。卷积块注意力模块 3

2. 我们通过大量的实验验证了注意力模块的有效性

化学研究。

3. 我们验证了各种网络的性能在以下方面得到了显著提升：

通过插件测试了多个基准测试（ImageNet-1K、MS COCO 和 VOC 2007）。

打造我们的轻量化模块。

2 相关工作

网络工程。“网络工程”一直是最重要的领域之一。

视觉研究至关重要，因为精心设计的网络能够确保卓越的性能。

在各种应用中实现性能提升。多种架构均已得到应用。

自大规模 CNN 成功实现以来，就有人提出了这一建议[19]。

一种直观且简单的扩展方法是增加神经网络的深度。

网络[9]。Szegedy 等人[10]引入了一种使用深度 Inception 网络的网络

多分支架构，其中每个分支都经过精心定制。

由于梯度难以控制，单纯增加深度会达到饱和。

为了简化传播过程，ResNet [5] 提出了一种简单的身份跳跃连接。

深度网络的优化问题。基于 ResNet 架构，各种

诸如 WideResNet [6]、Inception-ResNet [8] 和 ResNeXt [7] 等模型已经出现。WideResNet [6] 提出了一种具有更多单元的残差网络。卷积滤波器和降低深度。PyramidNet [20] 是一个严格的泛化模型。WideResNet 中网络的宽度逐渐增加。ResNeXt [7] 建议使用分组卷积，并表明增加基数从而提高分类准确率。最近，Huang 等人[21]提出一种名为 DenseNet 的新架构。它迭代地将输入特征与……连接起来。输出特征，使每个卷积块都能接收原始信息。从之前的所有模块来看，大多数最新的网络工程方法主要针对三个因素：深度[19, 9, 10, 5]、宽度[10, 22, 6, 8]和核心。在性[7, 11]中，我们关注另一个方面，“注意力”，这是其中一个有趣的方面。人类视觉系统的一部分。注意力机制。众所周知，注意力扮演着重要的角色。在人类感知中的作用[23-25]。人类视觉的一个重要特性是该系统的特点是不会尝试一次性处理整个场景。相反，人类利用一系列零碎的印象，并有选择地关注显著的信息。部分是为了更好地捕捉视觉结构[26]。最近，已有若干尝试[27, 28]将注意力纳入考量。处理以提高 CNN 在大规模分类任务中的性能。Wang 等人[27]提出了残差注意力网络，该网络使用编码器。解码器风格的注意力模块。通过细化特征图，网络不会不仅性能优异，而且对噪声输入也很有鲁棒性。而不是直接 com 引入 3D 注意力图，我们将学习通道的过程分解开来。注意力和空间注意力是分开的。注意力的产生是分开的。3D 特征图的处理过程计算量和参数量都远小于 Woo、Park、Lee 和 Kweon 等人提出的 4 个问题。

头部，因此可以用作现有底座的即插即用模块 CNN 架构。

与我们的工作更接近的是，Hu 等人[28]引入了一个紧凑的模块来利用通道间关系。在他们的挤压激励模块中，他们使用全局平均池化特征用于计算通道级注意力。然而，我们结果表明，这些特征不足以推断精细的通道注意力，我们也建议使用最大池化特征。它们也忽略了空间信息。注意力在决定关注“哪里”起着重要作用，正如所示：

[29] 在我们的 CBAM 中，我们利用了基于空间和通道的注意力机制一种高效的架构，并通过实证验证，同时利用这两种架构优于……仅使用通道级注意力机制，如[28]所示。此外，我们通过实验证明：我们的模块在检测任务（MS-COCO 和 VOC）中表现有效。特别是，我们只需将我们的模块放置在顶部，即可实现最先进的性能。VOC2007 测试集中的现有单次检测器 [30]。

3 卷积块注意力模块

给定一个中间特征图 $F \in \mathbb{R}^{C \times H \times W}$ 作为输入，CBAM 依次推断出一个一维通道注意力图 $M_c \in \mathbb{R}^{C \times 1 \times 1}$ 和一个二维空间注意力图如图 1 所示，将 $M_s \in \mathbb{R}^{1 \times H \times W}$ 映射到整体注意力过程。

可概括为：

$$\begin{aligned} F_0 &= M_c(F) \otimes F, \\ F_{00} &= M_s(F_0) \otimes F_0, \end{aligned} \quad (1)$$

其中 $\otimes$ 表示逐元素乘法。在乘法过程中，注意力值会相应地广播（复制）：频道注意力值是沿空间维度广播，反之亦然。 F_{00} 是最终精炼后的数值。输出。图 2 展示了每个注意力图的计算过程。

下面详细描述了每个注意力模块。

通道注意力模块。我们利用漏洞生成通道注意力图。

描述特征之间的通道间关系。特征图的每个通道都与特征图有关。通道注意力被视为一种特征检测器[31]，它关注的是“是什么”。给定输入图像，通道注意力有意义。为了高效地计算通道注意力，我们对输入特征图的空间维度进行压缩。为了聚合 spa 总体信息，平均池化是目前普遍采用的方法。Zhou 等人。

[32] 建议利用它来有效地了解目标对象的范围，Hu 等人等人[28]在其注意力模块中采用了该方法来计算空间统计数据。我们认为，在之前的研究基础上，最大池化收集到了另一个重要的线索。通过识别独特的物体特征来推断更精细的通道注意力。因此，我们同时使用平均池化和最大池化特征。我们经验表明实际证实，利用这两个特性可以显著提高表示效果。

与其独立使用每个网络，不如利用网络的力量（参见第 4.1 节），这表明我们设计选择的有效性。下面我们将详细描述其运行过程。卷积块注意力模块 5 最大池

平均池

渠道关注

MC

频道注意力模块

[最大池化时间, 平均池化时间]

空间注意力

多发性硬化症

空间注意力模块

输入特征 F

通道精炼

特征 F'

共享 MLP

转换

层

图 2: 各注意力子模块示意图。如图所示, 通道

子模块同时利用最大池化输出和平均池化输出。

共享网络; 空间子模块利用类似的两个输出, 这两个输出是

沿通道轴进行池化, 然后将其传递到卷积层。

我们首先利用平均值聚合特征图的空间信息。

池化和最大池化操作, 生成两种不同的空间上下文

脚本: F_c^{avg} 和 F_c^{max} , 分别表示平均池化特征和最大池化特征。

分别描述特征。然后, 这两个描述符被转发到一个共享网络。

为了生成我们的通道注意力图 $M_c \in \mathbb{R}^{C \times 1 \times 1}$, 共享网络是

由一个隐藏层的多层感知器 (MLP) 组成。为了减少

参数开销, 隐藏激活大小设置为 $RC/r \times 1 \times 1$, 其中 r 为

缩减率。在将共享网络应用于每个描述符之后, 我们

使用逐元素求和法合并输出特征向量。简而言之,

通道注意力计算公式如下:

$$\begin{aligned} M_c(F) &= \sigma (MLP(AvgPool(F)) + MLP(MaxPool(F))) \\ &= \sigma (W_1(W_0(F_c^{avg})) + W_1(W_0(F_c^{max}))), \end{aligned} \quad (2)$$

其中 σ 表示 sigmoid 函数, $W_0 \in \mathbb{R}^{C/r \times C}$, $W_1 \in \mathbb{R}^{C \times C/r}$ 。注意

MLP 的权重 W_0 和 W_1 对于两个输入都是共享的, 并且 ReLU 函数也是共享的。

激活函数之后是 W_0 。

空间注意力模块。我们利用以下方式生成空间注意力图：

特征之间的空间关系。与通道注意力不同，

空间注意力集中于“在哪里”这一信息部分，这是 com 的一部分。

与通道注意力机制互补。为了计算空间注意力，我们首先

沿通道轴应用平均池化和最大池化操作，

将它们连接起来以生成高效的特征描述符。应用池化

沿通道轴线的操作已被证明能有效突出信息。

tive 区域 [33]。在连接的特征描述符上，我们应用卷积 6 Woo、Park、Lee、Kweon

渠道注意力

ResBlock + CBAM

下一个

卷积块

以前的

卷积块

F

空间注意力

转换

MC

多发性硬化症

F'

F''

图 3: CBAM 与 ResNet[5] 中的 ResBlock 集成。该图显示

我们的模块在 ResBlock 中集成时的确切位置。我们应用

对每个块中的卷积输出进行 CBAM 处理。

生成空间注意力图 $M_s(F) \in \mathbb{R}^{H \times W}$ 的层，该注意力图编码了位置信息。

强调或抑制。我们将在下文中详细描述操作步骤。

我们通过使用两个池化来聚合特征图的通道信息。

操作生成两个 2D 地图: $F_s^{\text{avg}} \in \mathbb{R}^{1 \times H \times W}$ 和 $F_s^{\text{max}} \in \mathbb{R}^{1 \times H \times W}$ 。

每个符号分别表示通道的平均池化特征和最大池化特征。

然后将它们连接起来，并通过一个标准的卷积层进行卷积。

生成我们的二维空间注意力图。简而言之，空间注意力是……

写成：

$$M_s(F) = \sigma(f_{7 \times 7}([\text{AvgPool}(F); \text{MaxPool}(F)]))$$

$$= \sigma(f_{7 \times 7}([F_s^{\text{avg}}; F_s^{\text{max}}])),$$

(3)

其中 σ 表示 sigmoid 函数, $f_{7 \times 7}$ 表示卷积运算

滤波器尺寸为 7×7 。

注意力模块的排列。给定一幅输入图像, 两个注意力模块分别对应两个注意力模块。

模块、通道和空间, 计算互补注意力, 专注于

分别对应“什么”和“哪里”。考虑到这一点, 可以放置两个模块。

以并行或串行的方式。我们发现串行排列方式更合适。

与平行排列相比, 这种排列方式能获得更好的结果。对于这种排列方式而言,

顺序过程, 我们的实验结果表明通道一阶

比空间优先方法略好。我们将讨论实验结果。

第 4.1 节中的网络工程。

4 个实验

我们在标准基准测试集上评估 CBAM: ImageNet-1K 用于图像分类

分类; MS COCO 和 VOC 2007 用于目标检测。为了执行

为了更好地进行同类比较, 我们重现了所有评估的网络[5 -

在 PyTorch 框架 [35] 中, 我们复现了 7、34、28 等结果, 并在其中报告了我们的复现结果。

整个实验。

为了全面评估我们最终模块的有效性, 我们首先执行

大量的消融实验。然后, 我们验证了 CBAM 的性能优于所有卷积块注意力模块 7。

不带任何花哨功能的基准线, 展示了其普遍适用性

CBAM 可应用于不同的架构和不同的任务。人们可以将其连接起来。

将 CBAM 无缝集成到任何 CNN 架构中, 并联合训练组合模型。

CBAM 增强型网络。图 3 显示了 CBAM 与……集成的示意图。

以 ResNet 中的 ResBlock 为例 [5]。

4.1 消融研究

在本小节中, 我们将通过实证研究证明我们设计选择的有效性。

在本消融研究中, 我们使用 ImageNet-1K 数据集, 并采用 ResNet-50 [5] 作为模型。

基础架构。ImageNet-1K 分类数据集 [1] 由 1.2 个数据集组成。

100 万张图像用于训练, 5 万张图像用于验证, 包含 1000 个对象类别。

我们采用与 [5, 36] 相同的数据增强方案进行训练并应用

测试时采用 224×224 像素的单作物评估。学习率

初始值从 0.1 开始, 每 30 个周期递减一次。我们训练网络 90 个周期。

根据[5, 36, 37], 我们报告验证集上的分类错误。

我们的模块设计流程分为三个部分。首先, 我们寻找……

首先，采用有效的方法计算通道注意力，然后计算空间注意力。

最后，我们考虑如何将通道注意力模块和空间注意力模块结合起来。

下面我们将详细解释每个实验。

通道注意力。我们通过实验验证了使用平均池化

最大池化特征能够实现更精细的注意力推断。我们比较了 3 种不同的方法。

通道注意力机制的多种方法：平均池化、最大池化以及二者的联合使用

池化。请注意，带有平均池化的通道注意力模块是

与 SE [28] 模块相同。此外，当同时使用两种池化方案时，我们使用共享池。

用于注意力推理的 MLP 可保存参数，因为两者都是聚合通道

特征位于同一语义嵌入空间。我们仅使用通道注意力机制。

本实验中，我们将模块数量固定为 16，缩减率固定为 16。

表 1 展示了各种合并方法的实验结果。

观察可知，最大池化特征与平均池化特征同样有意义。

比较相对于基线的准确率提升。在 SE[28]的工作中，

然而，他们只利用了平均池化特征，忽略了其他重要特征。

描述

参数 GFLOPs 前 1 错误率(%) 前 5 错误率(%)

ResNet50（基线）

2556 万

3.86

24.56

7.50

ResNet50 + AvgPool（SE [28]）

2592 万

3.94

23.14

6.70

ResNet50 + MaxPool

2592 万

3.94

23.20

6.83

ResNet50 + AvgPool 和 MaxPool

2592 万

4.02

22.80

6.52

表 1：不同通道注意力方法的比较。我们观察到
结果表明，我们提出的方法优于最近提出的 Squeeze 方法。
激励方法[28].8 Woo, Park, Lee, Kweon

描述

参数：GFLOPS 前 1 错误率(%) 前 5 错误率(%)

ResNet50 + 通道 (SE [28])

2809 万

3.860

23.14

6.70

ResNet50 + 通道

2809 万

3.860

22.80

6.52

ResNet50 + 通道 + 空间 (1x1 卷积, k=3) 2810 万

3.862

22.96

6.64

ResNet50 + 通道 + 空间 (1x1 卷积, k=7) 2810 万

3.869

22.90

6.47

ResNet50 + 通道 + 空间 (平均值和最大值, k=3) 28.09M

3.863

22.68

6.41

ResNet50 + 通道 + 空间 (平均值和最大值, k=7) 28.09M

3.864

22.66

6.31

表 2：不同空间注意力方法的比较。使用提出的通道池化方法（即沿通道轴的平均池化和最大池化）以及后续卷积运算中较大的内核尺寸 7 表现最佳。

描述

前 1 个错误率(%) 前 5 个错误率(%)

ResNet50 + 通道 (SE [28])

23.14

6.70

ResNet50 + 通道 + 空间

22.66

6.31

ResNet50 + 空间 + 通道

22.78

6.42

ResNet50 + 通道和空间并行

22.95

6.59

表 3：通道注意力和空间注意力相结合的方法。同时使用两者注意力至关重要，而最佳组合策略（即顺序、渠道）首先）进一步提高准确性。

最大池化特征。我们认为，编码了最大池化特征的最显著部分的权重可以弥补平均池化特征的不足，对全局统计数据软编码。因此，我们建议同时使用这两个特征。neously 并将共享网络应用于这些特征。共享网络的输出然后通过逐元素求和合并网络。我们通过实验证明：我们的渠道关注方法是进一步提升绩效的有效途径。来自 SE [28]，无需额外的可学习参数。简而言之，我们在我们的通道注意力模块中同时使用平均池化特征和最大池化特征。以下实验中的还原率为 16。

空间注意力。鉴于通道级精细化特征，我们探索了一种有效的……计算空间注意力的有效方法。设计理念是对称的。使用通道注意力分支生成二维空间注意力图。

我们首先计算一个二维描述符，该描述符对每个像素的通道信息进行编码。

对所有空间位置。然后，我们对二维描述应用一个卷积层。

tor，得到原始注意力图。最终的注意力图通过以下方式归一化：

S 型函数。

我们比较了两种生成二维描述符的方法：通道池化

使用跨通道轴的平均池化和最大池化以及标准的 1×1 连接

演化将信道维度降低到 1。此外，我们还研究了

卷积层中内核大小的影响：内核大小为 3 和 7。

在实验中，我们将空间注意力模块放置在先前的卷积块注意力模块 9 之后。

设计了通道注意力模块，因为最终目标是同时使用这两个模块。

一起。

表 2 显示了实验结果。我们可以观察到该通道

合并操作能产生更高的准确率，这表明显式建模的合并操作

导致更精细的注意力推断，而不是可学习的加权通道池化

（以 1×1 卷积实现）。在不同卷积的比较中

对于不同的核函数值，我们发现采用更大的核函数值可以提高准确率。

两种情况下都如此。这意味着需要广阔的视野（即较大的感受野）。

为了确定空间上重要的区域。考虑到这一点，我们采用该通道

池化方法和具有较大卷积核尺寸的卷积层用于计算

空间注意力。简而言之，我们使用平均池化和最大池化。

沿通道轴方向，卷积核大小为 7 的特征作为我们的空间特征。

注意力模块。

通道排列和空间注意力。在本实验中，

我们比较了三种不同的通道和空间注意力安排方式

子模块：顺序通道-空间、顺序空间-通道和并行

同时使用两个注意力模块。由于每个模块的功能不同，因此顺序也不同。

可能会影响整体性能。例如，从空间角度来看，

通道注意力机制是全局应用的，而空间注意力机制是局部应用的。

此外，很自然地会想到，我们可以将两个注意力输出结合起来以构建

一个 3D 注意力图。在这种情况下，两种注意力机制可以并行应用。

将两个注意力模块的输出相加，并用以下公式进行归一化：

S 形函数。

表 3 总结了不同注意力安排的实验结果

ing 方法。从结果可以看出，生成注意力图

顺序推断比并行推断能得到更精细的注意力图。此外，

通道优先阶的性能略优于空间优先阶。请注意：
所有排序方法都优于仅使用通道注意力独立方法。
显然，这表明同时运用这两种注意力至关重要，而最佳安排是……
该战略进一步提升了业绩。
最终模块设计。在整个消融研究中，我们设计了……
通道注意力模块、空间注意力模块以及排列方式
这两个模块。我们的最终模块如图 1 和图 2 所示：我们选择
通道注意力模块和空间注意力模块均采用平均池化和最大池化；我们使用
在空间注意力模块中，我们使用核大小为 7 的卷积；我们安排
依次构建通道子模块和空间子模块。我们的最终模块（即 ResNet50）
+ CBAM）的 top-1 错误率为 22.66%，远低于 SE[28]（即
如表 4 所示，ResNet50 + SE。

4.2 ImageNet-1K 图像分类

我们进行了 ImageNet-1K 分类实验，以严格评估我们的结果。
模块。我们遵循与第 4.1 节中规定的相同协议，并评估我们的 10 Woo、Park、Lee、Kweon
建筑学

参数：GFLOPS 前 1 错误率 (%) 前 5 错误率 (%)

ResNet18 [5]

1169 万

1.814

29.60

10.55

ResNet18 [5] + SE [28]

1178 万

1.814

29.41

10.22

ResNet18 [5] + CBAM

1178 万

1.815

29.27

10.09

ResNet34 [5]

2180 万

3.664

26.69

8.60

ResNet34 [5] + SE [28]

2196 万

3.664

26.13

8.35

ResNet34 [5] + CBAM

2196 万

3.665

25.99

8.24

ResNet50 [5]

2556 万

3.858

24.56

7.50

ResNet50 [5] + SE [28]

2809 万

3.860

23.14

6.70

ResNet50 [5] + CBAM

2809 万

3.864

22.66

6.31

ResNet101 [5]

4455 万

7.570

23.38

6.88

ResNet101 [5] + SE [28]

4933 万

7.575

22.35

6.19

ResNet101 [5] + CBAM

4933 万

7.581

21.51

5.69

WideResNet18 [6] (加宽=1.5)

2588 万

3.866

26.85

8.88

WideResNet18 [6] (加宽=1.5) + SE [28] 26.07M

3.867

26.21

8.47

WideResNet18 [6] (加宽=1.5) + CBAM 26.08M

3.868

26.10

8.43

WideResNet18 [6] (widen=2.0)

4562 万

6.696

25.63

8.20

WideResNet18 [6] (加宽=2.0) + SE [28] 45.97M

6.696

24.93

7.65

WideResNet18 [6] (加宽=2.0) + CBAM 45.97M

6.697

24.84

7.63

ResNeXt50 [7] (32x4d)

2503 万

3.768

22.85

6.48

ResNeXt50 [7] (32x4d) + SE [28]

2756 万

3.771

21.91

6.04

ResNeXt50 [7] (32x4d) + CBAM

2756 万

3.774

21.92

5.91

ResNeXt101 [7] (32x4d)

4418 万

7.508

21.54

5.75

ResNeXt101 [7] (32x4d) + SE [28]

4896 万

7.512

21.17

5.66

ResNeXt101 [7] (32x4d) + CBAM

4896 万

7.519

21.07

5.59

* 所有结果均在 PyTorch 框架中重现。

表 4: ImageNet-1K 分类结果。单幅裁剪验证
报告了 rors。

模块应用于各种网络架构，包括 ResNet [5]、WideResNet [6]、以及 ResNext [7]。

表 4 总结了实验结果。采用 CBAM 的网络显著优于所有基线模型，表明 CBAM 可以这些模型在大规模数据集上具有良好的泛化能力。此外，这些模型 CBAM 提高了精度，优于最强的方法之一——SE [28] 这是 ILSVRC 2017 分类任务的获胜方法。这意味着我们提出的方法非常有效，展现了新型资金池的有效性。该方法能够生成更丰富的描述符和空间注意力，从而起到补充作用有效地吸引了渠道注意力。

图 4 展示了 ImageNet-1K 训练过程中各种网络的误差曲线。我们可以清楚地看到，我们的方法在训练和验证方面都表现出最低的误差。两个误差图中的误差均表明，CBAM 具有更强的改进能力。基线模型的泛化能力与 SE 相比 [28]。

我们还发现，CBAM 的总体开销在这两方面都相当小。

参数和计算。这促使我们应用我们提出的模块。

CBAM 到轻量级网络 MobileNet [34]。表 5 总结了

我们基于 MobileNet 架构进行的实验结果。

我们将 CBAM 分为两种模型：基本模型和容量缩减模型（即）。

将宽度乘数（ α ）调整为 0.7）。我们观察到与卷积块注意力模块 11 中所示的类似现象。

(a) ResNet50 [5] (b) MobileNet [34]

图 4：ImageNet-1K 训练过程中的误差曲线。彩色显示效果更佳。

建筑学

参数 GFLOPs 前 1 错误率 (%) 前 5 错误率 (%)

MobileNet [34] $\alpha = 0.7$

230 万

0.283

34.86

13.69

MobileNet [34] $\alpha = 0.7 + SE [28]$

271 万

0.283

32.50

12.49

MobileNet [34] $\alpha = 0.7 + \text{CBAM}$

271 万

0.289

31.51

11.48

移动网络 [34]

423 万

0.569

31.39

11.51

MobileNet [34] + SE [28]

507 万

0.570

29.97

10.63

MobileNet [34] + CBAM

507 万

0.576

29.01

9.99

* 所有结果均在 PyTorch 框架中重现。

表 5: 使用轻量级算法对 ImageNet-1K 进行分类的结果

网络, MobileNet [34]。报告了单作物验证错误。

如表 4 所示, CBAM 不仅显著提高了基线的精度, 而且

显著提升了 SE 的性能[28]。这表明其具有巨大的潜力。

CBAM 在低端设备上的应用。

4.3 使用 Grad-CAM 进行网络可视化 [18]

对于定性分析, 我们将 Grad-CAM [18] 应用于不同的网络。

使用来自 ImageNet 验证集的图像。Grad-CAM 是最近提出的一种算法。

可视化方法, 利用梯度来计算重要性

卷积层中空间位置的计算。梯度计算过程如下:

对于一个独特的类别, Grad-CAM 结果清晰地显示了所关注的区域。

通过观察网络认为对预测至关重要的区域

在本课程中, 我们将尝试研究该网络如何有效地利用其特征。

我们比较了 CBAM 集成网络（ResNet50 +）的可视化结果

CBAM）与基线（ResNet50）和 SE 集成网络（ResNet50 + SE）。

图 5 展示了可视化结果。目标类别的 softmax 得分

图中也显示了这些内容。

如图 5 所示，我们可以清晰地看到 CBAM 的 Grad-CAM 掩模。

与其他方法相比，集成网络能更好地覆盖目标对象区域。

也就是说，集成了 CBAM 的网络能够很好地学习如何利用信息。

目标对象区域并从中聚合特征。请注意，目标类为 12 Woo、Park、Lee、Kweon。

P = 0.96340

P=0.87240

P=0.80736

P = 0.19994

P=0.14643

P=0.11857

P = 0.93707

P=0.77550

P=0.65681

P = 0.35248

P=0.25093

P=0.22357

P = 0.87490

P=0.70827

P=0.64185

P = 0.53005

P=0.15367

P=0.14763

P = 0.99085

P=0.97166

P=0.92236

P = 0.59662

P=0.26611

P=0.01176

P = 0.96039

P=0.89962

P=0. 58732

P = 0. 59790

P=0. 14804

P=0. 08126

P = 0. 84387

P=0. 72659

P=0. 67128

P = 0. 71000

P=0. 61595

P=0. 56834

P = 0. 98482

P=0. 96575

P=0. 85873

P = 0. 90806

P=0. 79829

P=0. 62856

P = 0. 78636

P=0. 73723

P=0. 68065

P = 0. 98567

P=0. 92250

P=0. 07429

尾蛙

卫生纸

喇叭

蜘蛛网

美洲白鹭

坦克

海堤

小型供暖器

槌球

鳗鱼

锤头鲨

爱斯基摩犬

雪豹
船桨
长腿蜘蛛
校车
输入
图像
ResNet50
ResNet50
+ SE
ResNet50
+ CBAM
输入
图像
ResNet50
ResNet50
+ SE
ResNet50
+ CBAM

图 5: Grad-CAM [18] 可视化结果。我们比较了可视化结果。
CBAM 集成网络 (ResNet50 + CBAM) 与基线模型的对比结果
(ResNet50) 和 SE 集成网络 (ResNet50 + SE)。grad-CAM 视觉
化值是针对最后卷积输出计算的。真实标签
每个输入图像的顶部都会显示该值, P 表示每个图像的 softmax 得分。
用于真实类别的网络。卷积块注意力模块 13

骨干
探测器
mAP@.5 mAP@.75 mAP@[.5, .95]
ResNet50 [5]
Faster-RCNN [41]
46.2
28.1
27.0
ResNet50 [5] + CBAM
Faster-RCNN [41]

48.2
29.2
28.1
ResNet101 [5]
Faster-RCNN [41]
48.4
30.7
29.1
ResNet101 [5] + CBAM Faster-RCNN [41]
50.5
32.6
30.8

* 所有结果均在 PyTorch 框架中重现。

表 6: MS COCO 验证集上的目标检测平均精度均值 (%)。

采用 Faster R-CNN [41] 检测框架, 并将我们的模块应用于基础网络。对于两个基线网络, CBAM 将 mAP@[.5, .95] 提升了 0.9。

骨干
探测器
mAP@.5 参数 (M)
VGG16 [9]
SSD [39]
77.8
26.5
VGG16 [9]
StairNet [30]
78.9
32.0
VGG16 [9]
StairNet [30] + SE [28]
79.1
32.1
VGG16 [9]
StairNet [30] + CBAM
79.3

32.1

MobileNet [34] SSD [39]

68.1

5.81

移动网络 [34] 楼梯网络 [30]

70.1

5.98

MobileNet [34] StairNet [30] + SE [28]

70.0

5.99

MobileNet [34] StairNet [30] + CBAM

70.5

6.00

* 所有结果均在 PyTorch 框架中重现。

表 7: VOC 2007 测试集上的目标检测 mAP(%)。我们采用

StairNet [30] 检测框架, 并将 SE 和 CBAM 应用于检测器。

CBAM 在所有优秀基线的基础上均有显著改进, 且额外开销微乎其微。

参数。

分数也相应提高。根据观察结果, 我们推测:

CBAM 的特征细化过程最终导致网络利用

具备这些特点。

4.4 MS COCO 目标检测

我们在 Microsoft COCO 数据集 [3] 上进行目标检测。

包括 8 万张训练图像 (“2014 年训练集”) 和 4 万张验证图像 (“2014 年”

val”)。使用 0.5 到 0.95 不同 IoU 阈值下的平均 mAP。

为了进行评估。根据[38, 39], 我们使用所有训练数据训练了我们的模型。

图像以及一部分验证图像, 其中保留了 5,000 个样本。

验证。我们的训练代码基于[40], 我们使用 490K 训练网络。

我们采用迭代法进行快速性能验证。我们采用 Faster-RCNN [41] 作为我们的

我们采用的检测方法和 ImageNet 预训练的 ResNet50 和 ResNet101[5]作为我们的模型。

基准网络。我们感兴趣的是通过插件来提高性能。

将 CBAM 应用于基线网络。因为我们使用了相同的检测方法。

所有模型的收益都只能归因于增强的表征能力。

功率由我们的模块 CBAM 提供。如表 6 所示, 我们观察到显著的-

与基线相比，性能有了显著提升，证明了其泛化能力。

CBAM 在其他识别任务中的表现。14 Woo、Park、Lee、Kweon

4.5 VOC 2007 目标检测

我们进一步在 PASCAL VOC 2007 测试集上进行了实验。在这个实验中，实验中，我们将 CBAM 应用于探测器，而之前的实验（Ta）

6）将我们的模块应用于基础网络。我们采用 StairNet [30] 框架。

这项工作是基于 SSD 的最强多尺度方法之一 [39]。

为了进行实验，我们在 PyTorch 平台上复现了 SSD 和 StairNet。

为了准确评估 CBAM 的性能提升并实现

mAP@.5 分别为 77.8% 和 78.9%，均高于原始准确率。

原始论文中报道了 racy。然后我们将 SE [28] 和 CBAM 放在右侧

对于每个分类器，细化由上采样组成的最终特征

预测之前，需考虑全局特征和相应的局部特征，并强制执行。

该模型能够自适应地选择有意义的特征。我们训练了所有模型。

在 VOC 2007 训练验证集和 VOC 2012 训练验证集（“07+12”）上，以及

在 VOC 2007 测试集上进行评估。训练总轮数为 250。

我们使用 0.0005 的权重衰减和 0.9 的动量。在所有实验中，

为简单起见，输入图像的大小固定为 300。

实验结果汇总于表 7。我们可以清楚地看到

CBAM 提高了所有具有两个骨干网络的强基线模型的精度。

网络。请注意，CBAM 的准确性提升带来的代价微乎其微。

参数开销表明，这种增强并非源于简单的容量增加。

增加，但这得益于我们有效的特征细化。此外，结果

使用轻量级骨干网络[34]再次表明 CBAM 可以

一种适用于低端设备的有趣方法。

5 结论

我们提出了卷积瓶颈注意力模块（CBAM），

一种提高 CNN 网络表征能力的新方法。我们应用

基于注意力机制的特征细化包含两个不同的模块：通道模块和

空间，并在保持以下特性的同时实现显著的性能提升

开销较小。对于通道注意力机制，我们建议使用最大池化。

结合平均池化特征，可以产生更精细的衰减。

比 SE [28] 更高效。我们通过利用空间信息进一步提升了性能。

注意。我们的最后一个模块（CBAM）学习如何强调什么以及在哪里强调或

有效抑制和优化中间特征。为了验证其有效性，我们利用各种最先进的模型和组件进行了广泛的实验已证实 CBAM 在三个不同的基准测试中均优于所有基准测试。数据集：ImageNet-1K、MS COCO 和 VOC 2007。此外，我们还进行了可视化。该模块究竟是如何根据输入图像进行推断的？有趣的是，我们观察到我们的模块能够引导神经网络正确地聚焦于目标对象。我们希望 CBAM 已成为各种网络架构的重要组成部分。